IMF Smart Education

MÁSTER EN DATA SCIENCE & BUSINESS ANALYTICS

MODELIZACIÓN DEL SENTIMIENTO DEL INVERSOR: CONSTRUCCIÓN Y ANÁLISIS DEL INDICADOR FEAR & GREED EN EL MERCADOS CRIPTO Y EVALUACIÓN DE SU CAPACIDAD EXPLICATIVA Y PREDICTIVA EN MERCADOS FINANCIEROS TRADICIONALES

TFM elaborado por: PATRICK MILLA LÓPEZ
Tutor/a de TFM: JUAN MANUEL MORENO LAMPARERO

- 23 DE MAYO DE 2026, GALWAY (IRLANDA)-

ÍNDICE

1. MARCO TEÓRICO 9

1.1 CONTEXTUALIZACIÓN DE LOS MERCADOS FINANCIEROS ANALIZADOS 9
1.2 HIPÓTESIS DE LOS MERCADOS EFICIENTES (HME) 12
1.3 INDICADORES TÉCNICOS Y MÉTRICAS CUANTITATIVAS DE MERCADO 13
1.4 INDICADOR FEAR & GREED 16
1.5 ESTRATEGIAS DE INVERSIÓN PASIVAS 17

2. DATOS Y METODOLOGÍA 18

2.1 ORIGEN Y NATURALEZA DE LOS DATOS 18
2.1.1 VARIABLES DE MERCADO (PRECIOS Y CAPITALIZACIÓN) 19
2.1.2 VARIABLES DE SENTIMIENTO Y TENDENCIAS 19

3. ANÁLISIS, MODELIZACIÓN Y DESARROLLO DEL ÍNDICE FEAR & GREED EN EL MERCADO DE CRIPTOMONEDAS 20

3.1 ESTANDARIZACIÓN DE DATOS 20
3.2 ANÁLISIS EXPLORATORIO 20
3.2.1 ANALISIS ESTRUCTURAL 21
3.2.2 ANÁLISIS UNIVARIANTE 21
3.2.3 ANALISIS BIVARIANTE 22
3.2.4 ANÁLISIS MULTIVARIANTE 23
3.3 MODELADO 24
3.3.1 FEATURE ENGINEERING 24
3.3.2 PREPARACIÓN DE DATOS Y ESCALADO DE DATOS 25
3.3.3 DESARROLLO DE MODELOS DE APRENDIZAJE AUTOMÁTICO 26

4. EVALUACIÓN DEL DESEMPEÑO FINANCIERO DEL ÍNDICE FEAR & GREED Y BACKTESTING COMPARATIVO 27

4.1 DESEMPEÑO DEL DCA Y FEAR & GREED A LARGO PLAZO (2018-2025) 27
4.1.1 DESEMPEÑO DEL DOLLAR COST AVERAGE A LARGO PLAZO 28
4.1.2 FEAR AND GREED & HOLD A LARGO PLAZO 30
4.1.3 CONCLUSIONES 31
4.2 ANÁLISIS DE ESTRATEGIA EN PERIODO DE TEST (2024-2025) 31
4.2.1 COMPRA ÚNICA EN FEBRERO DE 2024 32
4.2.2 COMPRA ÚNICA EN DICIEMBRE DE 2024 34
4.2.3 DOLLAR COST AVERAGE (DCA) 35
4.2.4 FEAR & GREED & HOLD CON INDICADOR REAL 37
4.2.5 FEAR & GREED & HOLD CON INDICADOR PROPIO 38
4.2.6 SWING TRADING CON NUESTRO MODELO FEAR & GREED 39
4.2.7 CONCLUSIONES 41

5. DESARROLLO DEL ÍNDICE FEAR & GREED EN EL S&P500: ANÁLISIS DEL DESEMPEÑO Y BACKTESTING COMPARATIVO FRENTE AL MERCADO 42

5.1 SELECCIÓN DE VARIABLES PARA LA CONSTRUCCIÓN DEL INDICADOR 42
5.2 ANALÍSIS EXPLORATORIO 42
5.2.1 ANÁLISIS ESTRUCTURAL 43
5.2.2 ANÁLISIS UNIVARIANTE 43
5.2.3 ANÁLISIS BIVARIANTE 44
5.2.4 ANÁLISIS MULTIVARIANTE 45
5.3 CONSTRUCCIÓN DEL INDICADOR FEAR & GREED EN EL S&P 500 46
5.3.1 BUSQUEDA HEURÍSTICA DE PARÁMETROS 46
5.3.2 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA) 47
5.3.3 TRANSFER LEARNING 47
5.4 BACK TESTING DE LAS ESTRATEGIAS EN EL PERIODO 2018-2025 48
5.3.2 DOLLAR COST AVERAGE (DCA) 48
5.3.3 FEAR & GREED CRIPTO (ORIGINAL) 49
5.3.4 BÚSQUEDA HEURÍSTICA DE PARÁMETROS 50
5.3.5 TRANSFER LEARNING SIN ESCALAR 51

5.3.6 TRANSFER LEARNING ESCALADO 51

6. DESARROLLO DEL ÍNDICE FEAR & GREED EN EL ORO: ANÁLISIS DEL DESEMPEÑO Y BACKTESTING COMPARATIVO FRENTE AL MERCADO 52

6.1 SELECCIÓN DE VARIABLES PARA LA CONSTRUCCIÓN DEL INDICADOR 52
6.2 ANÁLISIS EXPLORATORIO 53
6.2.1 ANÁLISIS UNIVARIANTE 53
6.2.2 ANÁLISIS BIVARIANTE 54
6.2.3 ANALÍSIS MULTIVARIANTE 55
6.3 CONSTRUCCIÓN DEL INDICADOR FEAR & GREED EN EL ORO 56
6.3.1 BÚSQUEDA HEURÍSTICA DE PARÁMETROS 56
6.3.2 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA) 57
6.3.3 TRANSFER LEARNING 57
6.4 BACK TESTING DE LAS ESTRATEGIAS EN EL PERIODO 2018-2025 58
6.4.2 FEAR & GREED CRIPTO (ORIGINAL) 58
6.4.3 BÚSQUEDA HEURÍSTICA DE PARÁMETROS 59
6.4.4 TRANSFER LEARNING SIN ESCALAR 60
6.4.5 TRANSFER LEARNING ESCALADO 60

7. CONCLUSIONES 61

8. BIBLIOGRAFÍA 63

ÍNDICE DE GRÁFICOS

Gráfico 1 Precio histórico oro frente a dólar....10
Gráfico 2 Precio histórico S&P 500 frente a dólar....11
Gráfico 3 Hipótesis de mercados eficientes....13
Gráfico 4 Ejemplo de medias móviles....14
Gráfico 5 Ejemplo de Índice de fuerza relativa (RSI)....15
Gráfico 6 Ejemplo Drawdown....15
Gráfico 7 Ejemplo Bandas de Bollinger....16
Gráfico 8 Estrategia DCA en BTC en el periodo 2018-2025....29
Gráfico 9 Estrategia DCA en ETH en el periodo 2018-2025....29
Gráfico 10 Estrategia Fear & Greed en BTC en el periodo 2018-2025....30
Gráfico 11 Estrategia Fear & Greed en ETH en el periodo 2018-2025....31
Gráfico 12 Estrategia de compra única en Febrero en BTC en el periodo de test....33
Gráfico 13 Estrategia de compra única en Febrero en ETH en el periodo de test....33
Gráfico 14 Estrategia de compra única en Diciembre en BTC en el periodo de test....34
Gráfico 15 Estrategia de compra única en Diciembre en ETH en el periodo de test....35
Gráfico 16 Estrategia DCA en BTC en el periodo de test....36
Gráfico 17 Estrategia DCA en ETH en el periodo de test....36
Gráfico 18 Estrategia Fear & Greed en BTC en el periodo de test....37
Gráfico 19 Estrategia Fear & Greed en ETH en el periodo de test....38
Gráfico 20 Estrategia Fear & Greed propio en BTC en el periodo de test....39
Gráfico 21 Estrategia Fear & Greed propio en ETH en el periodo de test....39
Gráfico 22 Estrategia de Swing Trading en BTC en el periodo de test....40
Gráfico 23 Estrategia de Swing Trading en ETH en el periodo de test....41
Gráfico 24 Estrategia DCA en S&P 500 en el periodo 2018-2025....49
Gráfico 25 Estrategia Fear & Greed cripto en S&P 500 en el periodo 2018-2025....50
Gráfico 26 Estrategia Fear & Greed busqueda heurística en S&P 500 en el periodo 2018-2025....50
Gráfico 27 Estrategia Fear & Greed transfer learning no escalado en S&P 500 en el periodo 2018-2025....51
Gráfico 28 Estrategia Fear & Greed transfer learning escalado en S&P 500 en el periodo de 2018-2025....52
Gráfico 29 Estrategia DCA en oro en el periodo 2018-2025....58
Gráfico 30 Estrategia Fear & Greed cripto en oro en el periodo 2018-2025....59
Gráfico 31 Estrategia Fear & Greed búsqueda heurística en Oro en el periodo 2018-2025....59
Gráfico 32 Estrategia Fear & Greed transfer learning sin escalar en Oro en el periodo 2018-2025....60
Gráfico 33 Estrategia Fear & Greed transfer learning escalado en Oro en el periodo 2018-2025....61

RESUMEN

Este trabajo de investigación demuestra que la integración de la psicología y el sentimiento de los inversores en los modelos cuantitativos aporta un valor predictivo real, optimizando de manera sorprendente la rentabilidad en los mercados financieros. A través de las simulaciones ejecutadas, se comprobó que todas las estrategias activas fundamentadas en el indicador Fear & Greed superaron los rendimientos obtenidos mediante el método pasivo Dollar Cost Averaging (DCA). Sin embargo, la evidencia empírica también revela que, si bien el sentimiento generalizado ofrece una base sólida para la toma de decisiones intermercado (si existe correlación entre estos mercados), el verdadero potencial y la máxima eficiencia en la gestión de carteras se alcanzan al combinar estos flujos conductuales con variables macroeconómicas y métricas de volatilidad propias de cada activo subyacente.

PALABRAS CLAVE

Sentimiento de mercado, Miedo, Codicia, Mercados Financieros, Análisis Exploratorio, Backtesting, Modelos Predictivos, Correlación Intermercado.

ABSTRACT

This research work demonstrates that integrating investor psychology and sentiment into quantitative models provides real predictive value, significantly optimizing returns in financial markets. Through the executed simulations, it was proven that all active strategies based on the Fear & Greed index outperformed the returns yielded by the passive Dollar Cost Averaging (DCA) method. However, empirical evidence also reveals that while generalized sentiment offers a solid foundation for intermarket decision-making (provided a correlation exists between these markets), the true potential and maximum efficiency in portfolio management are achieved by combining these behavioral flows with macroeconomic variables and volatility metrics intrinsic to each underlying asset.

KEYWORDS

Market Sentiment, Fear, Greed, Financial Markets, Exploratory Analysis, Backtesting, Predictive Models, Intermarket Correlation

INTRODUCCIÓN

El mundo financiero ha experimentado una transformación profunda en las últimas décadas como consecuencia del avance tecnológico. En 2008, en el contexto de la crisis financiera global, surgió una innovación que cambiaría para siempre la concepción del dinero y los sistemas de pago: Bitcoin. Esta tecnología fue creada por Satoshi Nakamoto como una alternativa al sistema bancario tradicional, basada en un modelo descentralizado que permitía realizar transacciones *peer-to-peer* sin la intervención de intermediarios financieros.

La red comenzó a operar en 2009, año en el que se registraron las primeras transacciones con un valor prácticamente simbólico. Uno de los episodios más conocidos tuvo lugar en 2010, cuando un programador estadounidense pagó 10.000 bitcoins por dos pizzas, en lo que hoy se considera la primera transacción comercial con esta criptomoneda. Aquella operación, estaba valorada en aproximadamente 42 dólares. Actualmente, 10.000 bitcoins serían unos 678 millones de dólares.

Desde entonces, Bitcoin ha pasado de ser un experimento tecnológico, a convertirse en un activo financiero global, alcanzando valoraciones superiores a los 125.000 dólares en sus máximos históricos y consolidándose dentro del top 10 de activos con mayor capitalización de mercado. En la actualidad, el mercado de criptomonedas está compuesto por millones de activos digitales y presenta una elevada capitalización agregada (más de 2 billones de dólares).

Este entorno combina oportunidades de rentabilidad extraordinaria, pero a la vez, riesgos igualmente significativos. La elevada incertidumbre, las expectativas especulativas y la rápida difusión de información convierten al mercado cripto en un escenario especialmente sensible al comportamiento emocional de los inversores.

En este contexto, el presente Trabajo de Fin de Máster examina el papel del sentimiento del inversor en los mercados de criptomonedas a través de la construcción y análisis de un indicador llamado *Fear & Greed* (miedo y codicia). Este indicador se construye a partir de diversas variables que capturan tanto el comportamiento del mercado como el sentimiento de los inversores. Entre los principales componentes se incluyen: momentum de precio, volatilidad, mercados derivad, composición del mercado, tendencias de palabras clave y métricas de interacción de usuarios. El

objetivo es, analizar todo este tipo de variables y determinar en qué medida las dinámicas emocionales influyen en la formación de precios y si dicho indicador presenta capacidad explicativa y predictiva, tanto dentro del ecosistema cripto como en su posible extensión a mercados financieros tradicionales.

Tras el análisis en el mercado cripto, el indicador será contrastado empíricamente en el S&P 500 y el mercado del oro, con el fin de evaluar si los indicadores de sentimiento pueden contribuir a anticipar la evolución de precios en activos de naturaleza más consolidada y regulada, en comparación con la elevada volatilidad característica de los mercados de criptomonedas.

Asimismo, se comparará la eficacia de este enfoque basado en el sentimiento con estrategias de inversión más convencionales empleadas por inversores principiantes, como el *Dollar Cost Averaging* (compras periódicas), entre otras, para determinar si el uso del indicador aporta ventajas significativas frente a métodos de inversión sistemáticos y menos dependientes de la psicología del mercado.

Estos índices mercados tradicionales como el S&P 500 y el Gold, han sido seleccionados por su amplio reconocimiento entre los inversores convencionales. Estos activos suelen ofrecer un rendimiento positivo a largo plazo mediante estrategias de inversión sistemáticas, superando generalmente la inflación. Además, resulta interesante analizar las diferencias entre estos mercados, ya que el S&P 500 y las criptomonedas han mostrado una correlación positiva en los últimos años, mientras que el oro tiende a presentar una correlación negativa en ciertos casos, actuando como valor refugio en períodos de inestabilidad, aunque en los últimos años todos están teniendo una tendencia alcista. Por ello, resulta relevante evaluar si el sentimiento de los inversores desempeña un papel significativo en la dinámica de estos mercados o si, es solo un papel fundamental en mercados más novedosos como el mercado cripto.

Este tema ha sido seleccionado motivado por la curiosidad del autor de investigar si existen diferencias significativas entre los inversores en criptomonedas y los de mercados financieros tradicionales, o si, por el contrario, el factor emocional desempeña un papel fundamental en todos los mercados, permitiendo potencialmente anticipar movimientos de precios y aprovechar dichas dinámicas sin ser un experto en la materia.

OBJETIVO PRINCIPAL

El objetivo principal del proyecto es analizar el papel del sentimiento del inversor en la formación de precios mediante el análisis, construcción y validación del indicar Fear & Greed, evaluando su

capacidad explicativa y predictiva en el mercado cripto y explorando su aplicabilidad en mercados financieros tradicionales como el S&P500 y el oro.

OBJETIVOS ESPECÍFICOS

En el marco de este proyecto, se plantean diversos objetivos más específicos que ayudarán a lograr el principal, entre los cuales destacan los siguientes:

1. **Recopilación y análisis de datos del mercado cripto:** Obtener variables relevantes del mercado de criptomonedas y estudiar su relación con el indicador Fear & Greed mediante diferentes fuentes de información.
2. **Análisis exploratorio de datos (EDA):** Realizar un análisis descriptivo y estadístico de las variables recopiladas para comprender su comportamiento y posibles patrones de correlación con el sentimiento del mercado y en concreto, con el indicador.
3. **Evaluación predictiva en criptomonedas:** Analizar la capacidad del indicador Fear & Greed para explicar y predecir la evolución de los precios pasados y, en la medida de lo posible, anticipar movimientos futuros del mercado cripto.
4. **Comparación con estrategias de inversión convencionales:** Evaluar la rentabilidad y eficiencia del uso del indicador frente a estrategias sencillas de inversión, como el Dollar Cost Averaging (DCA) o el Buy & Hold.
5. **Extensión a mercados tradicionales:** Construir un indicador Fear & Greed adaptado a mercados financieros tradicionales (S&P 500 y oro) y analizar su capacidad explicativa y predictiva en estos activos.
6. **Evaluación de rendimiento en mercados tradicionales:** Comparar la rentabilidad obtenida mediante el uso del indicador en mercados tradicionales frente a estrategias sistemáticas como DCA y *Buy & Hold*.

1. MARCO TEÓRICO

1.1 CONTEXTUALIZACIÓN DE LOS MERCADOS FINANCIEROS ANALIZADOS

En el presente proyecto se analizarán distintas alternativas de inversión, abarcando tanto el mercado de criptomonedas como mercados financieros tradicionales como la renta variable y los activos refugio. Dado que el estudio se centra en el comportamiento del sentimiento del inversor y su posible impacto en estos mercados, resulta fundamental comprender, aunque sea de forma breve, el funcionamiento, las características estructurales y la naturaleza de cada uno de ellos.

Para comprender la evolución de los mercados financieros y el papel del sentimiento en ellos, resulta apropiado comenzar hablando del que probablemente es, el activo más antiguo del planeta: el oro. A lo largo de la historia, el oro ha sido uno de los bienes más valorados por la humanidad, no solo por sus propiedades físicas, sino también por su simbolismo económico y cultural.

Su uso se remonta a las primeras civilizaciones, por ejemplo, en Egipto, donde ya era considerado un símbolo de poder, divinidad y riqueza. Posteriormente, en la Antigüedad clásica (500 a.C), comenzaron a acuñarse monedas de oro, consolidándolo como medio de intercambio y reserva de valor.

Durante siglos, el oro ha estado asociado a prosperidad y estabilidad económica. Episodios históricos como la fiebre del oro en el siglo XIX o la implantación y también salida del patrón oro en el siglo XX reforzaron su papel como referencia monetaria y respaldo de sistemas financieros.

Una de sus principales características es la escasez. El oro es un recurso limitado cuya extracción requiere importantes costes y esfuerzo, lo que restringe su oferta. Esta limitación contrasta con las monedas fiduciarias modernas, como el dólar o el euro, cuya emisión depende de decisiones de política monetaria. Esta diferencia ha contribuido a que el oro sea percibido tradicionalmente como activo refugio frente a la inflación o la incertidumbre económica y los inversores quieran invertir en este activo tanto de forma digital como física. Esto ha dado lugar a importantes revaloraciones del precio del oro respecto al euro o el dolar:

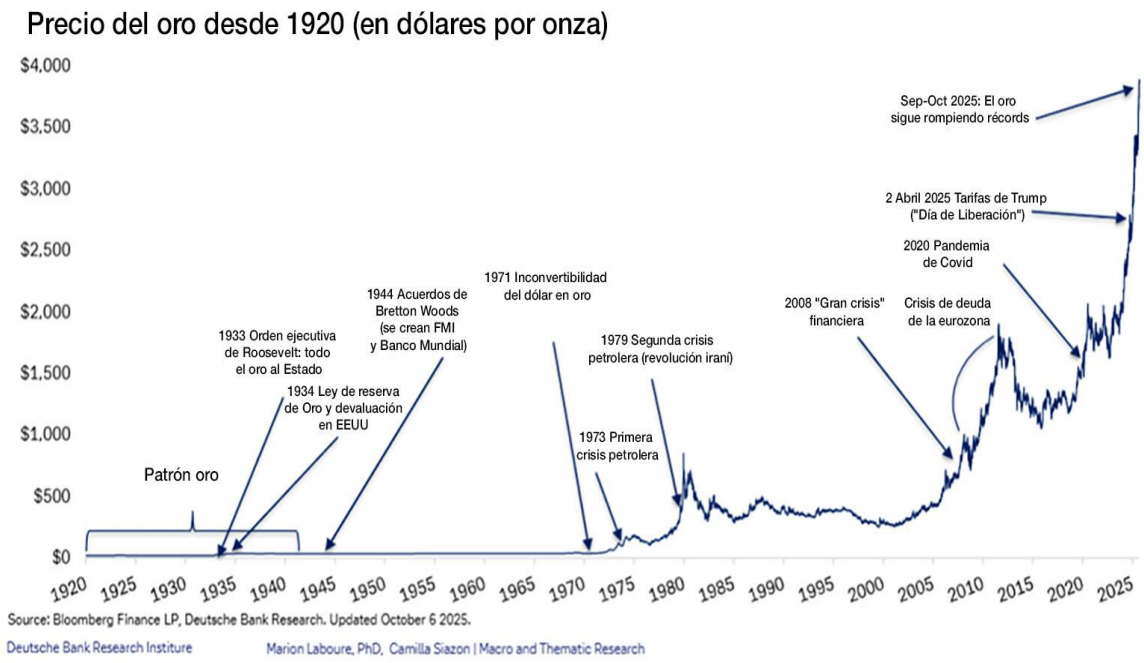


Gráfico 1 Precio histórico oro frente a dólar

En la actualidad, el acceso al oro se ha democratizado. Además de la adquisición física, los inversores pueden exponerse a este activo a través de instrumentos financieros como ETF, fondos de inversión u otros productos cotizados, lo que facilita su integración en carteras diversificadas.

Otro de los mercados fundamentales objeto de análisis en este trabajo es el S&P 500, uno de los principales índices bursátiles a nivel mundial y referencia del mercado de renta variable estadounidense.

El S&P 500 fue creado en 1957 y está compuesto por 500 de las empresas de mayor capitalización bursátil que cotizan en las principales bolsas de Estados Unidos, como el NYSE y el NASDAQ. Debido a su composición, el índice representa aproximadamente el 80% de la capitalización total del mercado bursátil estadounidense, lo que lo convierte en un indicador ampliamente utilizado para medir la evolución de la economía y del mercado financiero del país.

Entre las compañías que forman parte del índice se encuentran algunas de las mayores empresas tecnológicas y corporativas del mundo, como Apple, Nvidia, Amazon o Meta.

Desde el punto de vista del inversor, el S&P 500 constituye una opción atractiva por su alto grado de diversificación, al permitir exposición indirecta a cientos de empresas a través de un único instrumento. Históricamente, ha mostrado rentabilidades medias superiores a la inflación a largo plazo, lo que lo ha consolidado como uno de los activos preferidos para los inversionistas. Al ser

interesante para todo tipo de inversores este índice ha presentado grandes revalorizaciones a largo plazo frente a monedas fiat como el euro o el dolar:

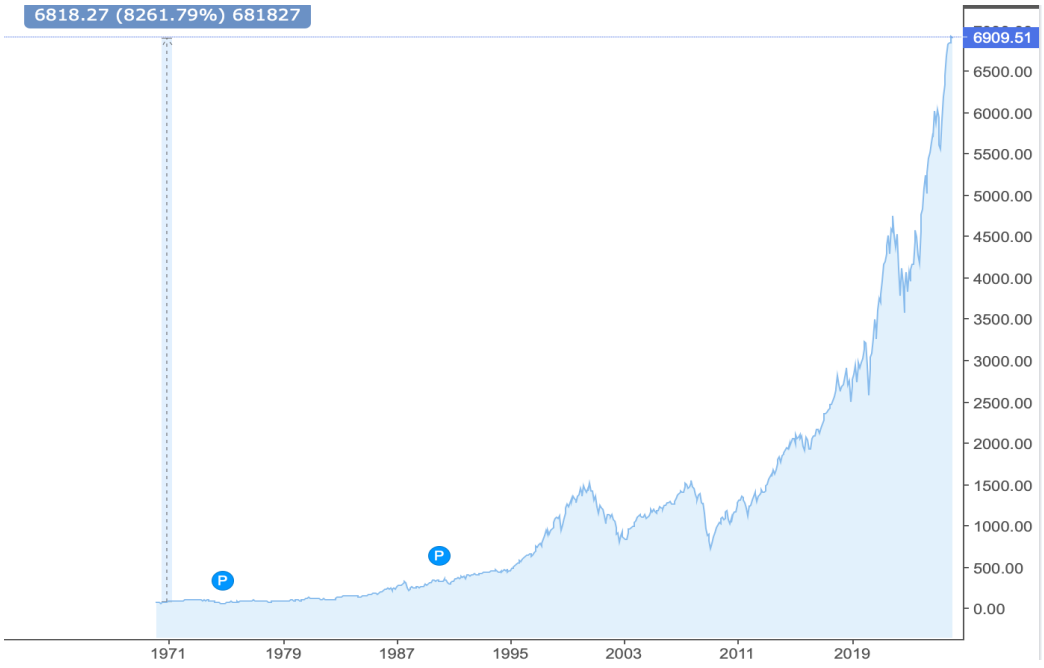


Gráfico 2 Precio histórico S&P 500 frente a dólar

En la actualidad, la forma más habitual de invertir en este índice es mediante instrumentos financieros como ETF, fondos indexados o fondos de inversión que replican su comportamiento, facilitando el acceso tanto a inversores institucionales como minoristas.

Finalmente, se analizará el mercado de criptomonedas, considerado uno de los desarrollos financieros más disruptivos y novedosos de la última década y quizás, hasta ahora, del siglo.

Este mercado surge en 2009 con la creación de Bitcoin por parte de Satoshi Nakamoto, cuya propuesta consistía en desarrollar un sistema monetario descentralizado, sin intermediarios financieros y sin dependencia de autoridades centrales. La innovación fundamental que acompañó a Bitcoin fue la tecnología blockchain, un sistema de registro distribuido que funciona como un libro contable digital donde se almacenan todas las transacciones de forma segura, transparente e inmutable. Una de sus principales características es que no está controlada por una autoridad central, es decir, no necesitas un banco para realizar transacciones, lo puedes hacer peer-to-peer (P2P).

Más tarde, en 2015, se lanzó la primera versión de Ethereum, actualmente la segunda criptomoneda con mayor capitalización de mercado, que amplió el alcance de la tecnología blockchain al permitir la ejecución de contratos inteligentes y aplicaciones descentralizadas. A

partir de entonces, el ecosistema cripto experimentó un crecimiento acelerado, dando lugar a la aparición de miles de nuevos proyectos y activos digitales.

En 2021, El Salvador se convirtió en el primer país en adoptar Bitcoin como moneda de curso legal, reflejando el creciente reconocimiento institucional del sector. Además, diversos países mantienen reservas significativas de Bitcoin, como, por ejemplo, Estados Unidos, China, Reino Unido o Emiratos Árabes Unidos.

Actualmente, el mercado de criptomonedas cuenta con millones de activos digitales y una capitalización agregada que supera los dos billones (trillions) de dólares estadounidenses. A diferencia de los mercados tradicionales, el mercado cripto opera de manera continua las 24 horas del día, los 7 días de la semana, lo que contribuye a su elevada liquidez, pero también a una mayor volatilidad. Esta volatilidad genera oportunidades de rentabilidad significativa, aunque también implica riesgos sustanciales para los inversores.

1.2 HIPÓTESIS DE LOS MERCADOS EFICIENTES (HME)

La Hipótesis de los Mercados Eficientes (HME) sostiene que los precios de los activos financieros reflejan de manera inmediata y completa toda la información disponible en el mercado. Bajo este supuesto, ningún inversor podría obtener rendimientos sistemáticamente superiores al promedio del mercado ajustado por riesgo, ya que los activos no estarían ni infravalorados ni sobrevalorados de forma persistente.

De acuerdo con esta teoría, las variaciones en los precios únicamente podrían explicarse por la llegada de nueva información inesperada. Una vez incorporada dicha información, el mercado volvería a un estado de eficiencia, ajustando rápidamente los precios a su valor “correcto”. Asimismo, la hipótesis asume que los participantes del mercado actúan de manera racional y que procesan la información de forma objetiva y sin sesgos sistemáticos.

Tradicionalmente, se distinguen tres formas de eficiencia:

- **Forma débil:** establece que los precios actuales ya incorporan toda la información contenida en los precios históricos y volúmenes de negociación. En consecuencia, los movimientos futuros no estarían relacionados con los pasados, lo que implicaría que el análisis técnico no permitiría obtener rentabilidades superiores de manera sistemática.
- **Forma semifuerte:** sostiene que los precios reflejan toda la información pública disponible (informes financieros, noticias económicas, datos macroeconómicos, etc.). Bajo esta

forma, ni el análisis técnico ni el análisis fundamental permitirían superar consistentemente al mercado.

- **Forma fuerte:** plantea que los precios incorporan toda la información existente, tanto pública como privada. En este escenario, ningún inversor podría obtener rendimientos anormales, incluso disponiendo de información privilegiada, salvo en circunstancias excepcionales. Por lo tanto, ni el análisis técnico ni el fundamental podrían dar ventajas para obtener beneficios superiores.

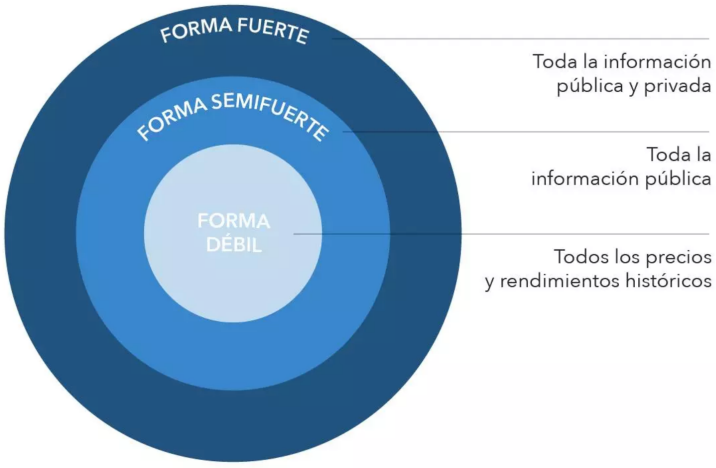


Gráfico 3 Hipótesis de mercados eficientes

En el presente trabajo se analizará si esta hipótesis puede resultar incompleta al no considerar la influencia de los factores psicológicos y los episodios de irracionalidad que pueden afectar a los participantes del mercado. En particular, se evaluará si estos componentes conductuales pueden generar ineficiencias detectables y, en su caso, si es posible identificarlas y analizarlas mediante herramientas cuantitativas aplicadas a indicadores de sentimiento, en concreto, mediante el indicador Fear & Greed.

1.3 INDICADORES TÉCNICOS Y MÉTRICAS CUANTITATIVAS DE MERCADO

Los indicadores técnicos constituyen herramientas cuantitativas basadas en el análisis matemático de variables históricas como el precio, el volumen o el comportamiento agregado del mercado.

A diferencia del análisis fundamental, estos indicadores se apoyan exclusivamente en información pasada, bajo el supuesto de que el comportamiento histórico del mercado puede aportar señales relevantes sobre su evolución futura.

En el presente proyecto se desarrollarán y utilizarán los siguientes indicadores técnicos:

- **Medias móviles:** Las medias móviles se emplean para suavizar las fluctuaciones del precio de un activo, reduciendo el ruido de corto plazo y permitiendo identificar la tendencia principal. Se calculan como el promedio del precio durante un periodo determinado y se actualizan de forma continua a medida que se incorporan nuevos datos. Existen distintas variantes, como la media móvil simple (SMA) o la media móvil exponencial (EMA), esta última otorgando mayor peso a los datos más recientes. Así se ven las medias móviles en un gráfico de velas japonesas:



Gráfico 4 Ejemplo de medias móviles

- **Momentum:** Mide la velocidad o intensidad con la que el precio de un activo varía en un determinado intervalo temporal. Se calcula habitualmente como la diferencia entre el precio actual y el precio de cierre de hace n periodos. Un valor positivo indica predominio de una tendencia alcista, mientras que un valor negativo refleja predominio de tendencia bajista. Cuanto mayor sea la magnitud del indicador (en valor absoluto),es decir, cuando más alejado este de 0, mayor será la fuerza del movimiento observado.
- **Índice de Fuerza Relativa (RSI):** El RSI o Índice de Fuerza Relativa es un oscilador que mide la velocidad y magnitud de los movimientos de precio. Su valor oscila entre 0 y 100 y se utiliza para identificar posibles situaciones de sobrecompra o sobreventa. Tradicionalmente, niveles superiores a 70 se interpretan como una condición de sobrecompra, lo que podría anticipar una corrección, mientras que valores inferiores a 30 se asocian con sobreventa y posibles rebotes al alza.

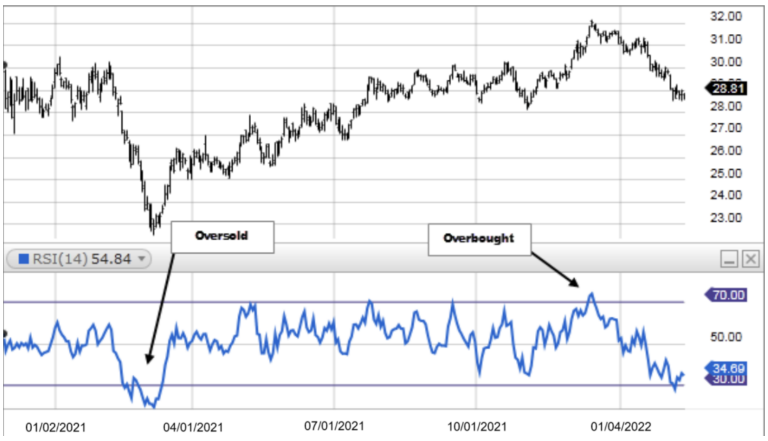


Gráfico 5 Ejemplo de Índice de fuerza relativa (RSI)

- **Volatilidad**: La volatilidad es una medida estadística que cuantifica la intensidad y frecuencia de las variaciones en el precio de un activo durante un periodo determinado. La volatilidad es una medida estadística que cuantifica la intensidad y frecuencia de las variaciones en el precio de un activo durante un periodo determinado.
- **Drawdown**: Cuantifica la caída máxima de un activo desde su punto más alto (pico) en un periodo de tiempo hasta su punto actual o más bajo (valle).

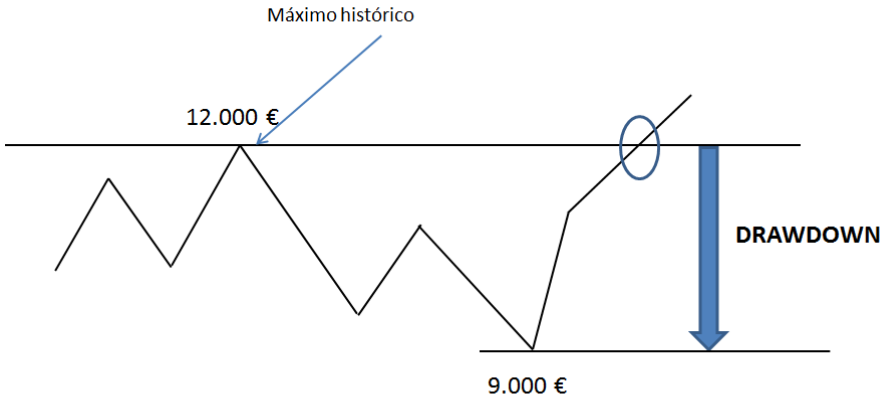


Gráfico 6 Ejemplo Drawdown

- **Tasa de cambio del precio (ROC)**: Compara el precio actual con el precio hace n periodos. Si el ROC sube por encima de cero, el mercado tiene impulso alcista; si cae por debajo de cero, el impulso es bajista.
- **Bandas de bollinger**: Es uno de los indicadores técnicos más utilizados en el análisis financiero y los modelos cuantitativos. Las bandas de Bollinger son 3 líneas que se situan encima de los gráficos de los precios de los activos: la banda superior (media móvil central

más dos desviaciones estándar), la banda central (media móvil simple) y la banda inferior (media móvil central menos dos desviaciones estándar).

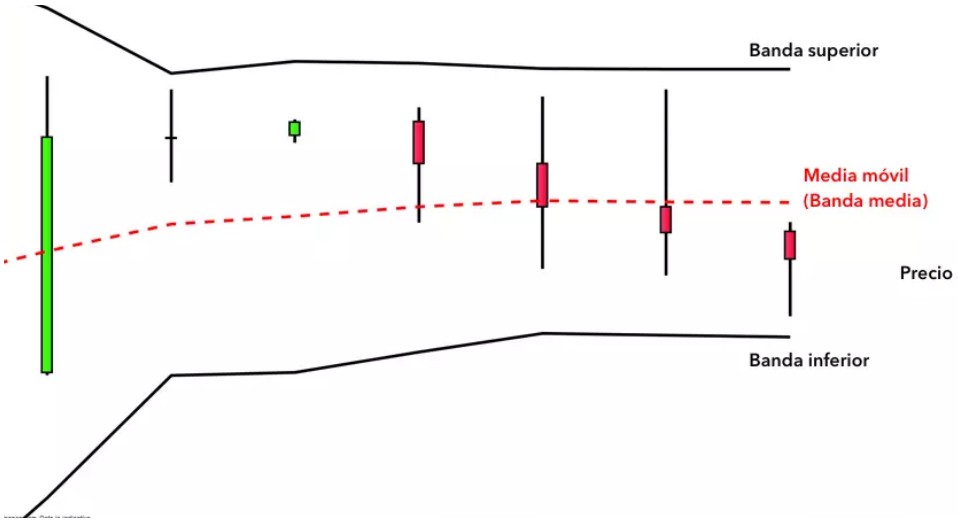


Gráfico 7 Ejemplo Bandas de Bollinger

Estos indicadores constituyen algunas de las variables que se utilizarán para la interpretación y el análisis del Fear & Greed, así como para su posible transferencia a otros mercados. En este sentido, el indicador de Fear & Greed, que se desarrollará en el siguiente apartado, combina información sobre volatilidad, momentum y otras variables junto con elementos de sentimiento del mercado, proporcionando una perspectiva complementaria que integra la dimensión emocional en el análisis financiero.

1.4 INDICADOR FEAR & GREED

El índice Fear & Greed es una herramienta que mide el sentimiento de los participantes en los mercados financieros. Su finalidad es cuantificar, en una escala de 0 a 100, el grado predominante de miedo o codicia que influye en las decisiones de inversión en un momento determinado.

En términos interpretativos, valores inferiores a 25 suelen asociarse con situaciones de miedo extremo (Extreme Fear), lo que podría reflejar episodios de sobreventa, elevada aversión al riesgo o pánico generalizado. Estos niveles podrían interpretarse como oportunidades de compra, en la medida en que el activo podría encontrarse infravalorado. Por el contrario, valores superiores a 75 se vinculan con codicia extrema (Extreme Greed), lo que indicaría un entorno de euforia o exceso de confianza, potencialmente asociado a situaciones de sobrevaloración y mayor probabilidad de corrección.

Desde una perspectiva teórica, el índice se enmarca en el ámbito de la economía conductual, disciplina que sostiene que los precios de los activos no siempre reflejan exclusivamente fundamentos económicos, sino que están influenciados por sesgos cognitivos y emociones colectivas.

Uno de los aspectos más relevantes del índice Fear & Greed es que no responde a una fórmula universalmente estandarizada. Su construcción depende de la selección de variables del sentimiento y de la ponderación asignada a cada una de ellas. Por lo que se tendrán que utilizar diferentes técnicas de ponderación de variables para ver cual de ellas encaja mejor en nuestros mercados.

En el presente proyecto se tomará como referencia el índice Fear & Greed del mercado de criptomonedas, utilizando su estructura conceptual como base para posteriores aplicaciones a otros mercados financieros. En el ámbito cripto, el índice suele construirse a partir de diversas variables, entre las que destacan:

- **Volatilidad:** análisis de la volatilidad actual de Bitcoin en comparación con sus medias históricas, normalmente, en ventanas de 30 a 90 días.
- **Impulso y volumen de mercado:** evaluación del volumen de negociación y del momentum reciente en relación con promedios históricos, con el objetivo de identificar presión compradora o vendedora.
- **Actividad en redes sociales:** monitorización de menciones, hashtags e interacciones en plataformas digitales, analizando intensidad y velocidad.
- **Dominancia de Bitcoin:** medida del peso relativo de Bitcoin sobre la capitalización total del mercado cripto. En determinados contextos, un aumento de la dominancia puede interpretarse como una búsqueda de activos relativamente menos volátiles dentro del ecosistema, lo que podría asociarse a episodios de mayor aversión al riesgo.
- **Tendencias de búsqueda:** datos procedentes de Google Trends, que permiten analizar la evolución en la frecuencia de búsqueda de términos relacionados con el mercado. Ej: Bitcoin Crash, Bitcoin Scam…
- **Encuestas de sentimiento:** recopilación de opiniones de inversores minoristas en distintas plataformas especializadas.

1.5 ESTRATEGIAS DE INVERSIÓN PASIVAS

Aparte del análisis del indicador en los distintos mercados comentados anteriormente, se van a comparar distintas estrategias de inversión sencillas, accesibles para un inversor sin necesidad de

una gestión activa ni conocimientos avanzados de análisis financiero. En particular, se evaluará el desempeño de diversas estrategias pasivas frente a una estrategia basada en señales derivadas de un indicador de sentimiento de mercado, concretamente un índice de *Fear & Greed*.

La finalidad del estudio es analizar si la incorporación sistemática de información relacionada con el sentimiento agregado de los inversores permite obtener rentabilidades ajustadas al riesgo superiores a las alcanzadas mediante enfoques tradicionales de inversión pasiva, sin incurrir en una elevada frecuencia operativa ni en decisiones discrecionales complejas. Las estrategias objeto de análisis en este trabajo son:

- **Buy & Hold:** Consiste en la inversión de la totalidad del capital en un único momento, manteniendo esta posición durante un horizonte temporal prolongado sin realizar ajustes. Esta estrategia se basa en la hipótesis de que los mercados financieros presentan una tendencia alcista en el largo plazo. Esta técnica se apoya en la teoría de mercados eficientes que dice que los precios incorporan de manera inmediata toda la información disponible con lo que no es posible obtener rentabilidades mediante estrategias más activas.
- **Dollar-cost Averaging (DCA):** Consiste en la inversión periódica de una cantidad fija en intervalo de tiempo regulares (quincenal, mensual, anual…) sin importar la tendencia del activo. El DCA reduce la volatilidad del mercado debido a que estas comprando sin importar el precio del activo de forma que algunas veces entraras en picos y otras en valles.

2. DATOS Y METODOLOGÍA

2.1 ORIGEN Y NATURALEZA DE LOS DATOS

Dado que la metodología exacta del índice *Fear & Greed* original no es pública, este estudio propone una reconstrucción basada en variables mercado y en variables que el mercado identifica como predictores de sentimiento.

El dataset final se ha construido mediante la integración de múltiples fuentes de datos, abarcando desde Febrero de 2018 (fecha de creación del índice original) hasta el 31 de Diciembre de 2025. Aparte de las variables que se van a comentar a continuación se agregarán más en el apartado de feature engineering a partir de las variables existentes.

2.1.1 VARIABLES DE MERCADO (PRECIOS Y CAPITALIZACIÓN)

Se han seleccionado activos estratégicos para capturar la salud general del ecosistema financiero:

- **Criptomonedas (Yahoo Finance):** Se extraen los precios de cierre diarios de las 10 principales criptomonedas por capitalización (BTC, ETH, XRP, BNB, SOL, TRX, DOGE, BCH, ADA, LEO). Esta selección permite al modelo entender si el sentimiento es sistémico o específico de ciertos activos.
- **Correlación de Mercados Tradicionales:** Se integran los precios de cierre del **S&P 500** y el **Oro**, con el fin de identificar periodos en los que existe algún tipo de relación entre mercados tradicionales y el mercado cripto.
- **Dominancia de Mercado:** Se recopila la capitalización de mercado de Bitcoin frente a la de las altcoins (todas las criptomonedas menos Bitcoin). Históricamente, un aumento en la dominancia de Bitcoin suele asociarse a periodos de miedo (los inversores se refugian en un valor menos volátil), mientras que el crecimiento de las altcoins indica fases de euforia (los inversores aceptan un mayor riesgo).

2.1.2 VARIABLES DE SENTIMIENTO Y TENDENCIAS

Para capturar la psicología del inversor más allá del precio, se incorporan variables de comportamiento masivo:

- **Sentimiento Institucional / Retail:** Se utiliza la encuesta de la *American Association of Individual Investors* (AAII) para validar si el sentimiento en los mercados de valores tradicionales actúa como un indicador adelantado para el mercado cripto.
- **Google Trends:**
    - **"Buy Bitcoin" (Web Search):** Utilizado como indicador de interés minorista entrante ante movimientos volátiles. Cuando el mercado de criptomonedas sufre crecimientos exponenciales la gente de a pie se empieza a interesan por las criptomonedas y las búsquedas en Google tienden a subir.
    - **"Crypto" (YouTube Search):** Utilizado como proxy de la actividad de los creadores de contenido y el hype mediático en plataformas audiovisuales. Al igual que en la palabra “buy bitcoin”, los creadores de contenido crean más videos cuando las criptomonedas están en una tendencia alcista.

2.1.3 VARIABLE OBJETIVO (TARGET)

- ***API Alternative.me:*** Se extrae el valor histórico del índice Fear & Greed original. Este valor actuará como nuestra variable objetivo ().

3. ANÁLISIS, MODELIZACIÓN Y DESARROLLO DEL ÍNDICE FEAR & GREED EN EL MERCADO DE CRIPTOMONEDAS

3.1 ESTANDARIZACIÓN DE DATOS

Antes de realizar el análisis y construir el modelo, fue necesario limpiar y organizar la información recolectada para que todas las fuentes fuesen más o menos homogéneas. Este proceso se centró en asegurar que los datos fueran coherentes y estuvieran listos para ser procesados.

Para garantizar que el estudio fuera preciso se realizaron los siguientes ajustes:

- **Gestión de fechas:** Se convirtió la columna de fecha a un formato estándar (Datetime) y se estableció como el índice principal. Esto es fundamental para que el modelo entienda el orden cronológico de los eventos.
- **Depuración de variables:** Se renombraron las columnas que tenían nombres confusos de las APIs originales y se eliminaron aquellas que no aportaban valor al estudio. Esto permitió trabajar con un conjunto de datos más limpio, sencillo y manejable para el análisis exploratorio.
- **Reescalado:** Se realizó un reescalado de los datos en las variables extraídas de Google Trends. Esto fue necesario debido a que esta herramienta tiene una limitación: si pides datos de varios años, te los da por semanas, pero si pides pocos meses, te los da por días. Para solucionar esto se dividió el periodo total en dos bloques más pequeños para poder extraer la información día a día. Como Google Trends ofrece valores relativos, se tuvieron que reescalar los datos. Este paso fue necesario para que las cifras de un bloque fueran comparables con las del siguiente, evitando que aparecieran saltos bruscos que pudieran confundir al modelo.
- **Construcción del dataframe:** Por último, para empezar el análisis exploratorio de datos, se concatenaron todas las variables en un mismo dataframe.

3.2 ANÁLISIS EXPLORATORIO

3.2.1 ANALISIS ESTRUCTURAL

El primer paso del análisis exploratorio consiste en realizar una inspección básica de la estructura del dataset consolidado con el objetivo de verificar que la arquitectura de la base de datos es sólida y detectar posibles anomalías técnicas que deban corregirse antes del modelado.

En este primer vistazo, se han observado los siguientes puntos clave:

- **Dimensiones y Tipología:** El dataset se compone de 2891 filas y 20 columnas. Se verificó que la mayoría de las variables financieras y de tendencias se cargaron correctamente, aunque se detectó que las variables de sentimiento "sent_bajista" y "sent_alcista" (provenientes de la encuesta AAII) estaban categorizadas como tipo object (texto). Para poder operar con ellas matemáticamente, se transformaron a tipo “float”.
- **Inspección de rangos:** Mediante una revisión de los valores mínimos y máximos, se comprobó que no existen valores anómalos, lo que confirma que las APIs funcionaron de forma consistente.
- **Detección de valores ausentes:** Se identificó la presencia de valores nulos en algunas variables específicas como el S&P500, el oro o criptomonedas como Solana y LEO, entre otras.

3.2.2 ANÁLISIS UNIVARIANTE

En primer lugar, se ha realizado un estudio individual de cada variable utilizando dos funciones: una función de visualización gráfica y otra de análisis estadístico descriptivo. Este proceso ha permitido identificar y corregir anomalías, asegurando que cada dato tenga una justificación lógica.

- **Criptomonedas:** El análisis reveló que la mayoría de los activos presentan una tendencia alcista a largo plazo, aunque con dinámicas distintas. Se detectaron valores nulos al inicio del periodo en SOL y LEO. Tras contrastar con fuentes externas, se confirmó que estas criptomonedas no habían sido lanzadas en febrero de 2018. Se decidió imputar el valor 0 para estos periodos.
- **S&P 500 y Oro:** Estas variables presentaban un patrón de nulos recurrente (2 días de ausencia por cada 5 de datos). La causa es el cierre de los mercados tradicionales en fines de semana y festivos (como Navidad). Para evitar saltos artificiales en la serie temporal, se aplicó la técnica “forward fill”, manteniendo el último precio de cierre registrado hasta la reapertura del mercado.
- **Google Trends:** Se observa que el interés por las palabras "Buy Bitcoin" y "Crypto" alcanzó sus máximos históricos entre 2021 y 2022, coincidiendo con el mercado alcista. En

la variable "Crypto" (YouTube), el interés fue más prolongado en el tiempo. Se detectaron 3 nulos aislados que fueron corregidos mediante forward fill para mantener la continuidad.

- **Dominancia y volatilidad:** En cuanto a la dominancia, se identificó una caída significativa en 2022, periodo conocido como "Altseason" donde el capital fluyó hacia monedas alternativas (altcoins). Por otra parte, se detectó un único valor nulo el cual se corrigió mediante imputación por media lineal entre el día anterior y el posterior para preservar la tendencia local. Por otra parte, en cuanto a la volatilidad, se detectaron tres picos extremos. Al cruzar estos datos con eventos históricos, se validó que no eran errores: uno de ellos corresponde a la prohibición del comercio de criptomonedas en China, que provocó una caída masiva.
- **Encuesta de AAII:** Se observó que el sentimiento alcista y bajista son inversamente proporcionales y no presentan ningún valor anómalo ni nulos. Para evitar la multicolinealidad, se ha determinado que una de ellas deberá ser descartada en etapas posteriores.
- **Variable target (Fear & Greed):** El índice Fear & Greed mostró nulos puntuales que se resolvieron con forward fill. Visualmente, el índice guarda una relación directa con el precio de Bitcoin: valores de "Codicia extrema" en máximos históricos y "Miedo extremo" durante las correcciones bruscas.

3.2.3 ANALISIS BIVARIANTE

Para este análisis, se ha utilizado una función de visualización de doble eje que permite superponer la variable objetivo (Fear & Greed) con cada uno de los predictores. Este enfoque facilita la detección de patrones visuales y retrasos temporales entre el sentimiento y la acción del precio. Al analizar la variable target frente a las demás variables se han obtenido los siguientes hechos o hipótesis:

- **Criptomonedas:** Se observa que el índice Fear & Greed es altamente sensible a los movimientos del Top 10 de criptomonedas. La capacidad del indicador para detectar techos y suelos en la mayoría de ellas sugiere una fuerte correlación en el sector.
- **Volumen diario:** Existe una relación directa entre el volumen diario y las fases de Codicia (Greed). Esto confirma el comportamiento del inversor minorista, que tiende a entrar al mercado impulsado por el fenómeno FOMO (Fear of Missing Out) cuando los precios ya están al alza.
- **Volatilidad:** Al analizar los picos de volatilidad extrema, se comprobó que el indicador se hunde inmediatamente hacia el Miedo Extremo. No obstante, el análisis visual muestra que

el sentimiento suele recuperarse rápidamente tras estos eventos, lo que históricamente ha señalado oportunidades de compra.

- **Dominancia de Bitcoin:** Sorprendentemente, los periodos de baja dominancia de Bitcoin coinciden con niveles de "Miedo" en el índice (sobretodo en 2021). Esto sugiere que el pánico en esos momentos no solo era por el precio, sino por la incertidumbre generada por la volatilidad de las altcoins durante sus fases de expansión.
- **Encuesta AAII:** El sentimiento alcista de la AAII presenta similitudes con la variable target. Esto valida la hipótesis de que el S&P 500 y las criptomonedas comparten ciertos conductores macroeconómicos, aunque con diferentes niveles de intensidad.
- **Búsquedas Google Trends:** Las búsquedas muestran una alineación considerable con el sentimiento. Los máximos de popularidad en Google coinciden con cotas de codicia y con el momento en que Bitcoin alcanzaba sus máximos históricos, evidenciando que el sentimiento masivo es un motor clave del precio.

Además de la variable objetivo, se han analizado cruces estratégicos que aportan valor al contexto financiero del modelo:

- **S&P 500 vs. Bitcoin:** Ambos siguen trayectorias similares en picos y valles. Sin embargo, Bitcoin acentúa los movimientos debido a su menor capitalización frente a las 500 mayores empresas de EE. UU y a su mayor volatilidad.
- **Oro vs. Bitcoin:** Se detectó que entre 2020 y 2022, mientras el Oro lateralizaba o caía, Bitcoin se disparaba. Este fenómeno sugiere una rotación de capital: los inversores pudieron desplazar fondos del refugio tradicional (Oro) hacia el "Oro Digital" (Bitcoin) buscando mayores rentabilidades.
- **Búsquedas y Volumen vs. Precio:** Tanto el volumen como las visitas en Google muestran un comportamiento procíclico. Se disparan en las subidas (2021 y post-2023) y son mucho más bajos en los mercados bajistas, lo que indica que el interés del público es reactivo al precio.

3.2.4 ANÁLISIS MULTIVARIANTE

Para concluir el análisis exploratorio, se ha generado una matriz de correlación de Pearson utilizando la librería Seaborn. Este análisis permite cuantificar las relaciones lineales entre todas las variables del sistema simultáneamente, confirmando las sospechas de los análisis previos que se pudiesen tener anteriormente en el análisis univariante y bivariante. En la matriz de correlaciones se pueden observar las siguientes relaciones:

- **Ecosistema cripto:** Se confirma una correlación extremadamente alta entre la mayoría de las criptomonedas del Top 10. La excepción notable es BCH (Bitcoin Cash), que muestra una desvinculación relativa frente al resto.
- **Sentimiento Tradicional:** Tal como se preveía, pese a en los datos originales existir el sentimiento neutral, existe una correlación negativa casi perfecta entre el sentimiento alcista y bajista de la AAII. Por lo tanto, se confirma la necesidad de eliminar una de ellas para evitar ruido en el entrenamiento del modelo.
- **"Crypto" vs. Altcoins:** La palabra "crypto" presenta una correlación más fuerte con activos como ADA, DOGE o ETH que con el propio Bitcoin. Este fenómeno, sumado a la correlación negativa entre la búsqueda "crypto" y la dominancia de Bitcoin, sugiere que el interés masivo del público se dispara cuando el capital fluye de Bitcoin hacia las altcoins en busca de rentabilidades exponenciales. Es el indicador visual del "efecto FOMO" y de la fase de euforia del ciclo de mercado.
- **Variable target (Fear & Greed):** Al realizar un filtrado de las variables que más impactan en el Fear & Greed Index, se identifican las siguientes variables. Si hablamos de correlación positiva destacan las variables del sentimiento alcista, el precio de BTC, el volumen diario y la dominancia de Bitcoin. Estos podríamos decir que son los principales impulsores de la codicia. Por otra parte, en cuanto a correlación negativa, el sentimiento bajista destaca como el único factor de peso que drena la confianza del mercado, actuando como un contrapeso natural al sentimiento alcista.

3.3 MODELADO

3.3.1 FEATURE ENGINEERING

Una vez comprendida la naturaleza de los datos a través del análisis exploratorio, se procede a la fase de Ingeniería de Características (feature engineering). El objetivo es doble: simplificar el dataset eliminando el ruido y enriquecerlo creando nuevas variables que capturen patrones temporales, técnicos y psicológicos que las variables en bruto no muestran por sí solas.

En primera instancia, se realizó un proceso de filtrado basado en el análisis de multicolinealidad. Se eliminaron todas las criptomonedas secundarias, manteniendo únicamente Bitcoin (BTC) y Ethereum (ETH), debido a que todas las criptomonedas presentan una alta correlación entre ellas. Asimismo, en el ámbito del análisis de sentimiento, se decidió prescindir de la variable de "sentimiento bajista" en favor del "sentimiento alcista".

Después de la eliminación de variables, se han incorporado al modelo variables creadas a partir de otras variables existentes:

- **Variación diaria de Bitcoin:** Se ha añadido “BTC_var” y refleja el cambio porcentual del precio de Bitcoin en un día.
- **Relativa Strength Index (RSI):** Mide la velocidad y el cambio de los precios para indicar condiciones de compra y venta (parecido al fear & greed).
- **Media móvil de 50 periodos:** Se forma a través de la media de los precios de Bitcoin en los últimos 50 días. Se utiliza sobre todo para analizar tendencias.
- **VIX (CBOE Volatility Index):** Esta variable capta la volatilidad implícita del S&P500 en los próximos 30 días. Permite captar el sentimiento actual y futuro del mercado tradicional.
- **Volatilidad en Bitcoin de los últimos 7 días:** En esta variable se intenta capturar si se han producido movimientos bruscos en el precio de bitcoin
- **Bandas de Bollinger (Distancia a banda inferior):** Esta variable mide si el precio esta cerca de la banda inferior de Bollinger lo que indicaría que está llegando a zonas de soporte y que sería interesante comprar.
- **Ratio de cambio de 15 días:** Es un oscilador que mide el cambio porcentual del precio actual y el precio de hace 15 días.
- **Variación de hoy vs últimos 20 días:** Permite al modelo saber si el movimiento actual es una anomalía o si es lo normal dentro del rango de 3 semanas.
- **Distancia al precio máximo de 30 días y 60 días (drawdown):** Estas variables reflejan cuanto a caído el precio respecto al máximo de 30 y 60 días. Ayuda al modelo a identificar si estamos en una tendencia alcista en estos dos periodos.

3.3.2 PREPARACIÓN DE DATOS Y ESCALADO DE DATOS

Una vez finalizada la fase de ingeniería de atributos, el siguiente paso crítico es la estructuración y adecuación de los conjuntos de datos para el entrenamiento de los modelos de aprendizaje automático.

En primer lugar, se procedió a la separación de las variables en dos conjuntos diferenciados:

- **Matriz de Características (X):** Contiene todas las variables predictoras (indicadores técnicos, métricas de volatilidad y sentimiento).
- **Vector Objetivo (Y):** Contiene exclusivamente la variable target que el modelo debe predecir (Fear & Greed).

Después de separar los datos en X e Y se realiza una separación en periodos de train y test para el entrenamiento del modelo. Esta división no se realizará de manera aleatoria sino que se hará

una división cronológica debido a la naturaleza de los datos. Se establecieron los siguientes periodos:

- **Conjunto de Entrenamiento (train):** Comprende todos los datos desde el inicio de la serie (Febrero de 2018) hasta el 31 de diciembre de 2023.
- **Conjunto de Prueba (test):** Abarca desde el 1 de enero de 2024 hasta el 31 de diciembre de 2025.

Tras esta separación tanto en X en Y y en train y test se procede a la estandarización de las características (X) debido a que hay variables con unidades de medida y magnitudes muy dispares —como el precio de cotización de Bitcoin (en el orden de las decenas de miles), el RSI (escala 0-100) y variaciones porcentuales (decimales). Se ha optado por la técnica StandardScaler, la cual transforma cada característica para que tenga una media de 0 y una desviación típica de 1.

3.3.3 DESARROLLO DE MODELOS DE APRENDIZAJE AUTOMÁTICO

En esta fase, se evaluaron tres algoritmos de complejidad creciente para determinar cuál ofrecía la mejor capacidad predictiva sobre el índice Fear & Greed. Para garantizar la objetividad, se utilizaron las métricas RMSE (Root Mean Squared Error) y el Coeficiente de Determinación (R^2):

- **Regresión Lineal:** Los resultados obtenidos con este modelo fueron insatisfactorios. Se registró un RMSE de 46,96 —en una escala de 0 a 100— y un R^2 negativo. Estos valores indican que el modelo no fue capaz de captar la naturaleza no lineal de los datos, rindiendo incluso por debajo de una predicción aleatoria.
- **Random Forest:** Se aplicó una optimización de hiperparámetros mediante RandomizedSearchCV. El rendimiento mejoró sustancialmente respecto a la regresión lineal anterior, logrando un RMSE de 13,17 y un R^2 de 0,56. Un hallazgo relevante en este punto fue el análisis de la importancia de las variables (Feature Importance), donde se confirmó que los atributos creados durante la fase de feature engineering fueron los más determinantes, validando la estrategia de creación de nuevos indicadores.
- **XGBoost**: Este algoritmo, también optimizado con RandomizedSearchCV, proporcionó las mejores métricas del estudio con un RMSE de 15,27 y un R^2 de 0,41. Al igual que en Random Forest, las variables de ingeniería propia dominaron el modelo.

Tras comparar resultados entre los tres modelos realizados, se procedió a utilizar Random Forest por su menor RMSE y su mayor R^2. Al realizar un análisis visual comparativo entre el índice real y la predicción del Random Forest, se identificó un comportamiento conservador en el modelo

original: aunque seguía la tendencia, no alcanzaba con suficiente sensibilidad los picos de euforia extrema (>75) ni los valles de pánico extremo (<25).

Para corregir este sesgo y hacer el indicador operativo para la estrategia de inversión, se aplicó un reescalado mediante **MinMaxScaler**, forzando al indicador a cubrir el rango completo de [0, 100].

Este ajuste produjo los siguientes resultados:

- **Métricas post-escalado:** El RMSE aumentó ligeramente a 13,41 y el R^2 descendió a 0,55

A pesar del ligero deterioro en las métricas estadísticas, el índice escalado capturó con mucha mayor precisión los niveles extremos de sentimiento. Dado que el objetivo final no es solo la precisión estadística, sino la ejecución de señales de compra y venta en puntos críticos, se determinó que el indicador escalado es el más apto para el backtesting de la estrategia.

4. EVALUACIÓN DEL DESEMPEÑO FINANCIERO DEL ÍNDICE FEAR & GREED Y BACKTESTING COMPARATIVO

4.1 DESEMPEÑO DEL DCA Y FEAR & GREED A LARGO PLAZO (2018-2025)

Dado que el periodo de evaluación principal se circunscribe a los ejercicios 2024 y 2025, se estima metodológicamente necesario realizar primero una validación histórica extendida. El propósito es contrastar el desempeño de la estrategia Dollar Cost Average (DCA) frente al indicador Fear & Greed en un horizonte temporal mayor (2018-2026). Esta extensión permite analizar el comportamiento de ambos modelos a través de diversos ciclos económicos y distintos regímenes de volatilidad, aportando así una mayor robustez estadística a las conclusiones del estudio.

Para garantizar una comparativa homogénea y facilitar la interpretación de los datos, se han establecido las siguientes condiciones de simulación:

- **Periodo de estudio:** Desde el 2 de febrero de 2018 hasta el 31 de diciembre de 2025.
- **Presupuesto:** Se destina un capital inicial teórico de **10.000€** para cada una de las estrategias.
- **Activos:** El estudio se centra en Bitcoin (BTC) y Ethereum (ETH).

- **Simplificación de costes:** Las simulaciones se realizan **sin comisiones por operación**, permitiendo un análisis puro de la evolución del precio y la eficacia de los puntos de entrada.

4.1.1 DESEMPEÑO DEL DOLLAR COST AVERAGE A LARGO PLAZO

Esta estrategia como ya se comentó en puntos anteriores, es una estrategia de inversión pasiva, es decir, no requiere de atención del inversor, en la cual se invierte la misma cuantía mes a mes sin importar fluctuaciones del precio. Dado que el periodo de estudio está acotado entre Febrero de 2018 y Diciembre de 2025, se ha procedido a dividir el presupuesto inicial (10.000€) entre la duración total del experimento. Esto resulta en una cuota mensual (105,26€), la cual se invierte de forma automática el primer día de cada mes, independientemente del precio de cotización del activo o del sentimiento del mercado. En esta estrategia, al comprar tanto en máximos como en mínimos locales, el inversor adquiere más unidades del activo cuando el precio baja y menos cuando sube, logrando un precio medio de compra equilibrado.

Como se puede observar, en este periodo esta estrategia ha demostrado ser una metodología de inversión excepcionalmente sólida, validando por qué es el estándar de referencia para los inversores a largo plazo. La obtención de estas rentabilidades por supuesto se debe también al crecimiento exponencial que han tenido el mercado de las criptomonedas en el periodo estudiado.

En cuanto a Bitcoin, alcanza una rentabilidad del 478,73%. Este dato demuestra que la constancia en la acumulación permite capturar el crecimiento estructural del activo, mitigando el impacto de los mercados bajistas.

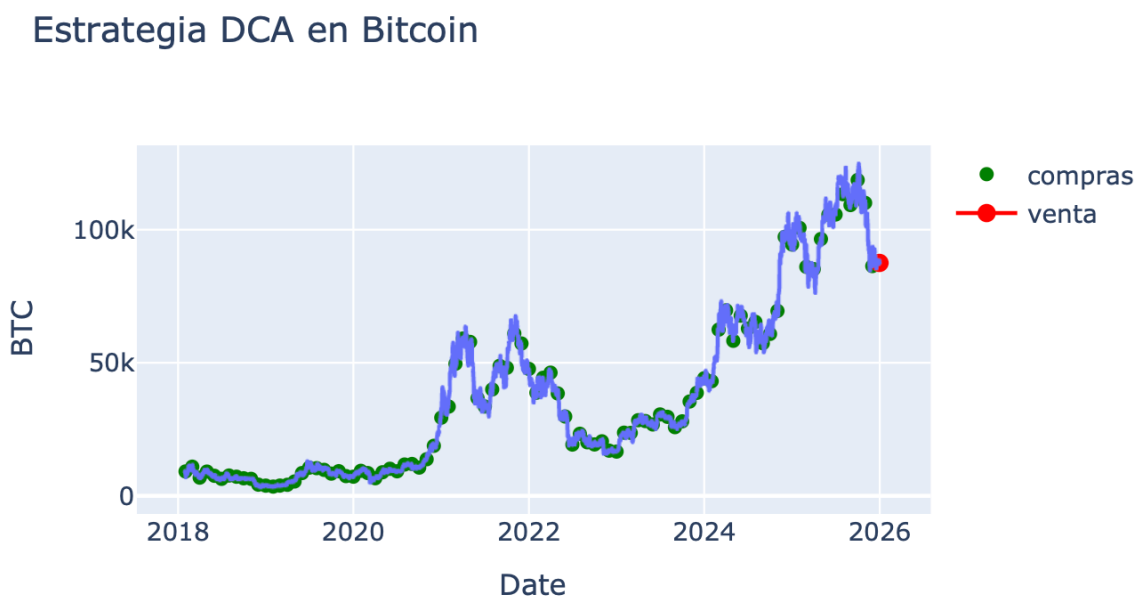


Gráfico 8 Estrategia DCA en BTC en el periodo 2018-2025

Por otro lado, Ethereum, logra un 473,23%, una cifra prácticamente idéntica a la de Bitcoin. Es relevante observar que, Ethereum no ofrece una prima de rentabilidad extra que justifique su mayor volatilidad. En este escenario, Bitcoin se posiciona como el activo más eficiente, ya que ofrece el mismo rendimiento con un perfil de riesgo sensiblemente menor.

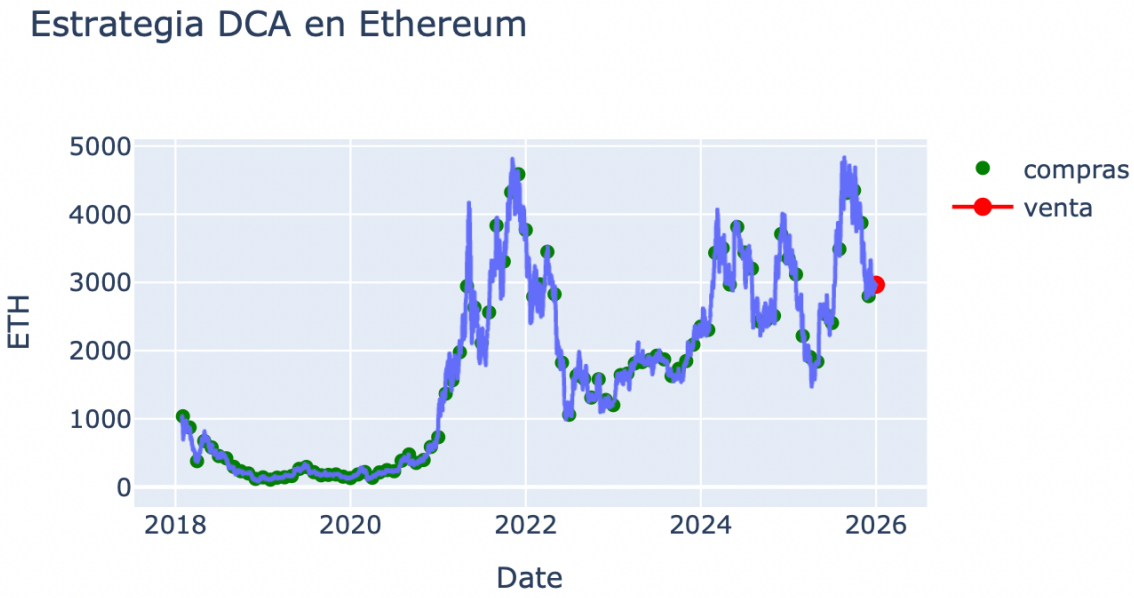


Gráfico 9 Estrategia DCA en ETH en el periodo 2018-2025

4.1.2 FEAR AND GREED & HOLD A LARGO PLAZO

En este escenario se abandona la inversión temporal fija (DCA) para pasar a una gestión condicionada por el sentimiento del mercado. Se ejecutará una orden de compra cada vez que el indicador Fear & Greed original presente un valor inferior a 25 incluso si se obtiene menos de 30 en días consecutivos. Para garantizar una comparativa justa y el agotamiento total del presupuesto (10.000€), se ha realizado un filtrado previo en el conjunto de datos para identificar el número total de jornadas en las que el indicador cerró por debajo del umbral de 30 dando lugar a una cuota de 17,89€ (mucho menor que la estrategia DCA).

Al analizar la estrategia basada en el índice de sentimiento, se observa que, al igual que en el DCA, los resultados son excepcionales debido al crecimiento exponencial del mercado cripto en los últimos ocho años. Sin embargo, la gestión basada en el miedo extremo logra optimizar significativamente los puntos de entrada, superando con claridad los rendimientos del DCA.

En primer lugar, BTC alcanza una rentabilidad del 692,80%. Al concentrar las compras en momentos donde el índice cae por debajo de 25, la estrategia logra acumular una mayor cantidad de activo durante los suelos de mercado (como el crash de marzo de 2020 o el mercado bajista de 2022), lo que dispara el beneficio final en comparación con el DCA.



Gráfico 10 Estrategia Fear & Greed en BTC en el periodo 2018-2025

Por otro lado, Ethereum no solo iguala a Bitcoin, sino que lo supera con una rentabilidad del 708,22% aunque la rentabilidad es mayor que la de BTC Ethereum presenta una volatilidad históricamente mayor; por tanto, el diferencial de rentabilidad del podría considerarse insuficiente para compensar la exposición a un perfil de riesgo sensiblemente más elevado."

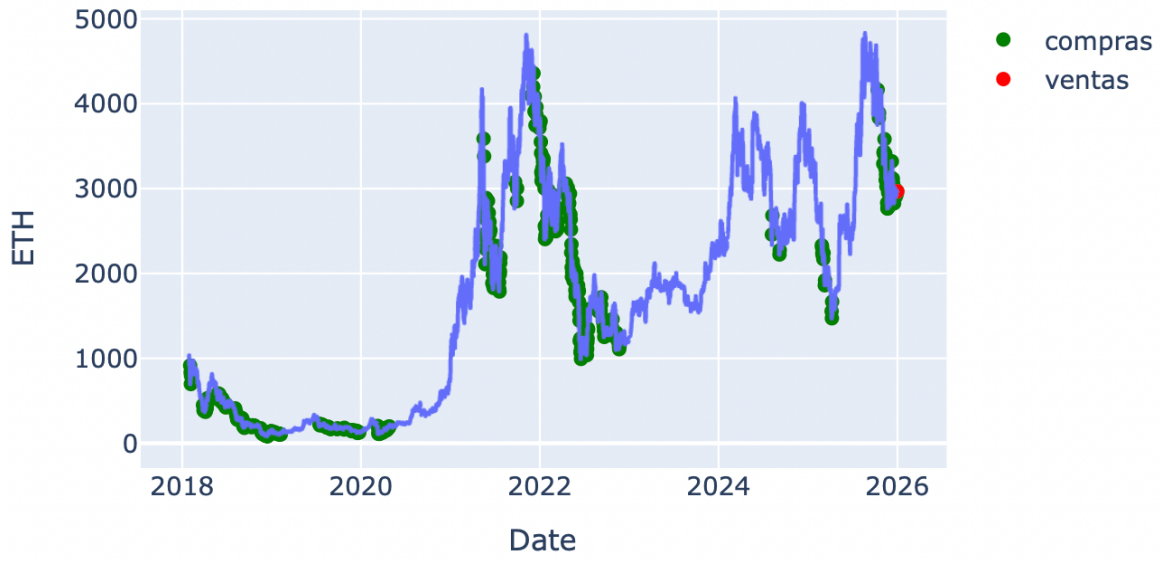


Gráfico 11 Estrategia Fear & Greed en ETH en el periodo 2018-2025

4.1.3 CONCLUSIONES

Tras comparar ambas estrategias, la conclusión principal es que el factor sentimiento transforma una inversión rentable en una inversión óptima. La diferencia no reside solo en el beneficio final, sino en la capacidad de la estrategia para acumular una mayor cantidad de activo con el mismo presupuesto (10.000€). Mientras que el DCA acumuló 0,66 BTC, el Fear & Greed logró almacenar 0,91 BTC. Esto supone haber adquirido un 37% más de Bitcoin simplemente optimizando el momento de entrada. Por el lado de ETH, El DCA acumuló 19,32 ETH, frente a los 27,24 ETH del Fear & Greed. En este caso, la estrategia de sentimiento permitió comprar un 41% más de Ethereum.

4.2 ANÁLISIS DE ESTRATEGIA EN PERIODO DE TEST (2024-2025)

En este capítulo, se evalúa el rendimiento del modelo desarrollado frente a diversas estrategias de inversión tradicionales. El objetivo es determinar si la capacidad predictiva de nuestro modelo permite optimizar la toma de decisiones y superar la rentabilidad del indicador Fear & Greed original, así como de otras metodologías de gestión de activos populares.

Las condiciones de este backtesting son:

- **Periodo de estudio:** Desde el 1 de enero de 2024 hasta el 31 de diciembre de 2025.

- **Activos analizados:** Se han seleccionado Bitcoin (BTC) y Ethereum (ETH). Esta elección permite contrastar el comportamiento del modelo en un activo de mayor capitalización y relativa estabilidad (BTC) frente a un activo de mayor volatilidad intrínseca (ETH).
- **Condición de cierre:** Para garantizar una comparativa equitativa, se ejecuta una liquidación obligatoria de todas las posiciones al cierre del periodo (31 de diciembre de 2025), independientemente del estado de las señales técnicas.
- **Simplificación de costes:** Las simulaciones se realizan sin comisiones por operación, permitiendo un análisis puro de la evolución del precio y la eficacia de los puntos de entrada.

4.2.1 COMPRA ÚNICA EN FEBRERO DE 2024

Este escenario simula la estrategia más simple de un inversor pasivo. Consiste en la ejecución de una única orden de compra con el 100% del capital en febrero de 2024, manteniendo la posición de forma ininterrumpida (estrategia Hold) hasta la liquidación final obligatoria el 31 de diciembre de 2025. El problema de esta estrategia es su vulnerabilidad y su riesgo. Al no existir un promediado de costes, si la compra se hubiese realizado en un máximo cíclico o en un punto no tan bueno, el inversor se enfrentaría a una rentabilidad negativa o muy baja.

En el caso de Bitcoin, esta estrategia ha arrojado una rentabilidad sensacional del 103,15%. Este resultado se explica por:

- La entrada se produjo de forma fortuita en el punto más bajo de la serie histórica del periodo de test.
- Durante 2024-2025, BTC experimentó un gran crecimiento por su madurez institucional. Al capturar el movimiento alcista desde su base, la estrategia maximiza el retorno, aunque asume un riesgo elevado al depender de un único punto de entrada.

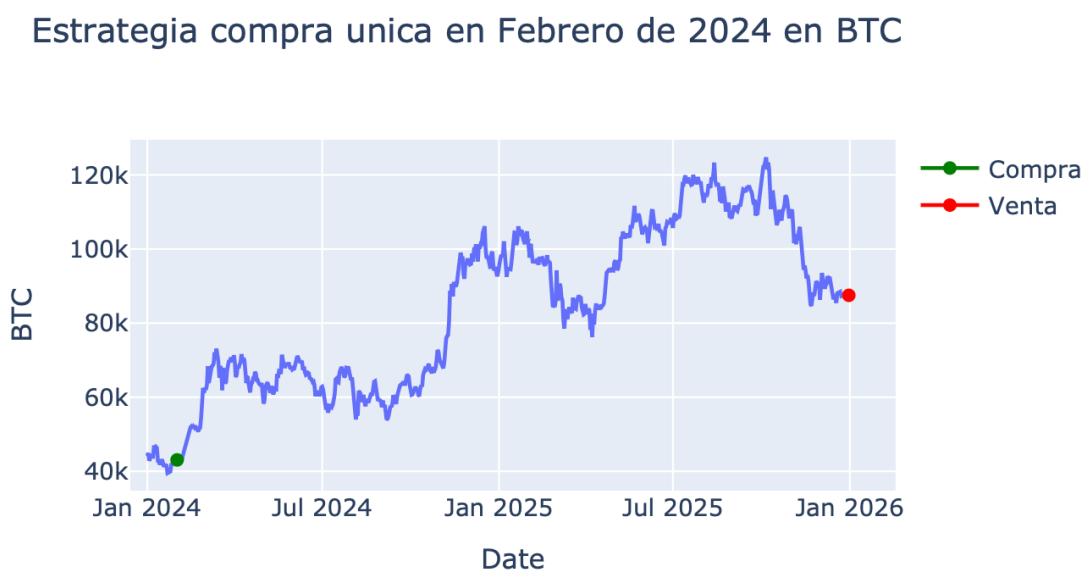


Gráfico 12 Estrategia de compra única en Febrero en BTC en el periodo de test

Para Ethereum, la estrategia obtuvo una rentabilidad del 28,78%. Aunque en términos absolutos se considera un retorno positivo y sólido para un periodo de dos años, la cifra queda significativamente rezagada frente a los resultados de BTC. A diferencia de Bitcoin, ETH no experimentó el mismo crecimiento durante este periodo. El precio fue más lateral o de crecimiento moderado, lo que penaliza la estrategia de compra única.



Gráfico 13 Estrategia de compra única en Febrero en ETH en el periodo de test

4.2.2 COMPRA ÚNICA EN DICIEMBRE DE 2024

Esta operativa mantiene la misma metodología que la anterior (inversión del 100% del capital en una sola orden y mantenimiento de la posición hasta el final del periodo), con la diferencia de que la entrada se ejecuta en diciembre de 2024. A diferencia del escenario de febrero, este punto de entrada sitúa al inversor en un contexto de mercado totalmente distinto. En diciembre de 2024, los activos ya habían experimentado una revalorización considerable, situándose en niveles de precios mucho más elevados.

En el caso de Bitcoin, la rentabilidad obtenida ha sido del -5,54%. A pesar del crecimiento general de BTC en el bienio, el precio de entrada a finales de 2024 resultó ser superior al precio de liquidación final en Diciembre de 2025:

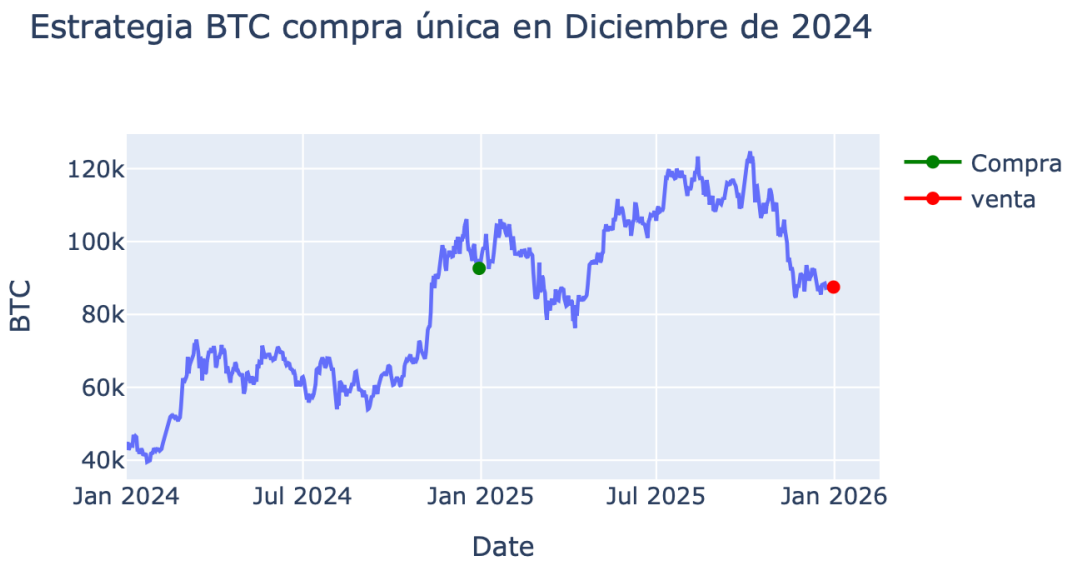


Gráfico 14 Estrategia de compra única en Diciembre en BTC en el periodo de test

Para Ethereum, el resultado es todavía más desfavorable, con una rentabilidad negativa del -11,6%. ETH, al tener una naturaleza más volátil y no haber experimentado el mismo impulso que BTC en este ciclo específico, castiga al inversor que no realiza una buena entrada:

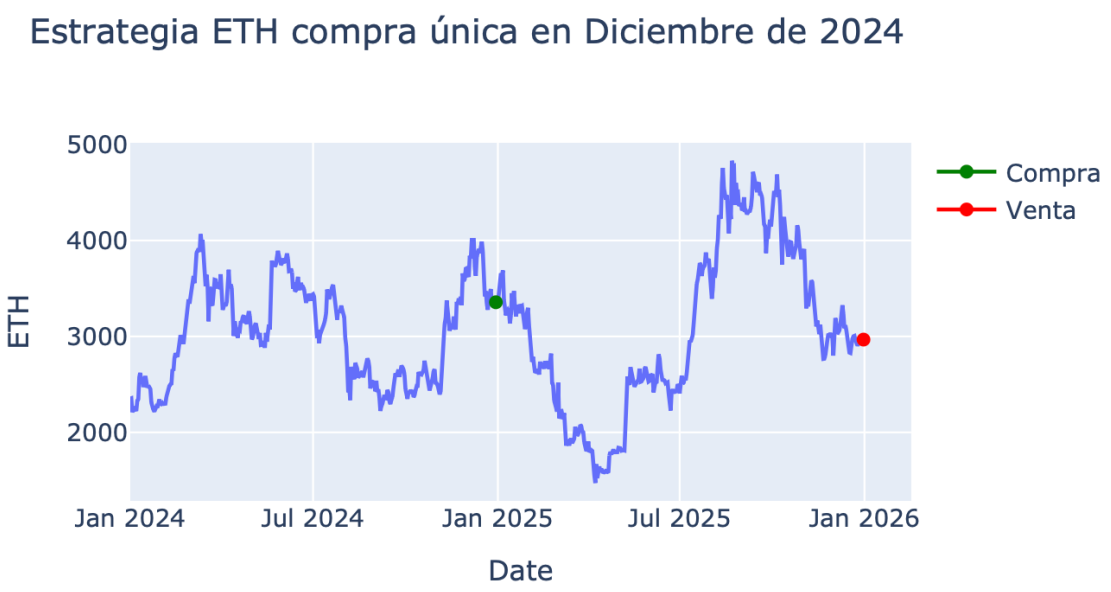


Gráfico 15 Estrategia de compra única en Diciembre en ETH en el periodo de test

4.2.3 DOLLAR COST AVERAGE (DCA)

El DCA es una metodología de inversión sistemática diseñada para reducir el impacto de la volatilidad y el riesgo. En lugar de realizar una inversión única como en la estrategia anterior, el capital total se fragmenta en aportaciones periódicas y constantes. La cuota mensual en este caso es de 416,17€ al mes.

En el caso de Bitcoin, la estrategia DCA ha generado una rentabilidad del 16,01%. Como se puede observar, este resultado es significativamente más bajo que la compra única de febrero de 2024, pero evita los rendimientos negativos de la compra tardía de diciembre de 2024:

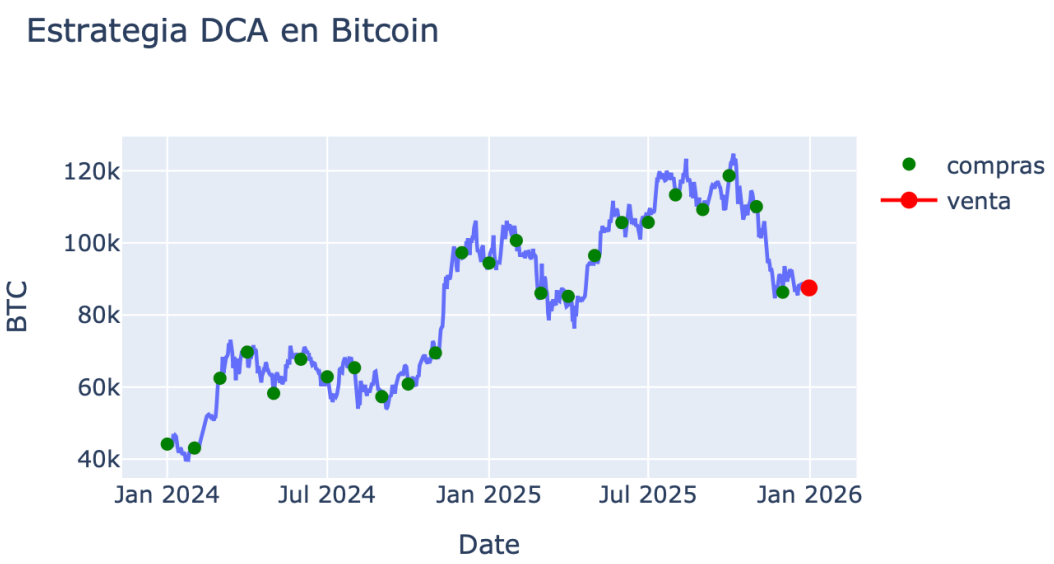


Gráfico 16 Estrategia DCA en BTC en el periodo de test

Para Ethereum, el DCA arroja una rentabilidad más modesta del 4,308%. Aunque la cifra es baja, es especialmente relevante compararla con el escenario de diciembre de 2024 (donde se perdía un 11,6%). El DCA ha cumplido su función principal: proteger al inversor de las entradas en máximos, logrando finalizar el periodo en terreno positivo a pesar del comportamiento lateral de ETH:

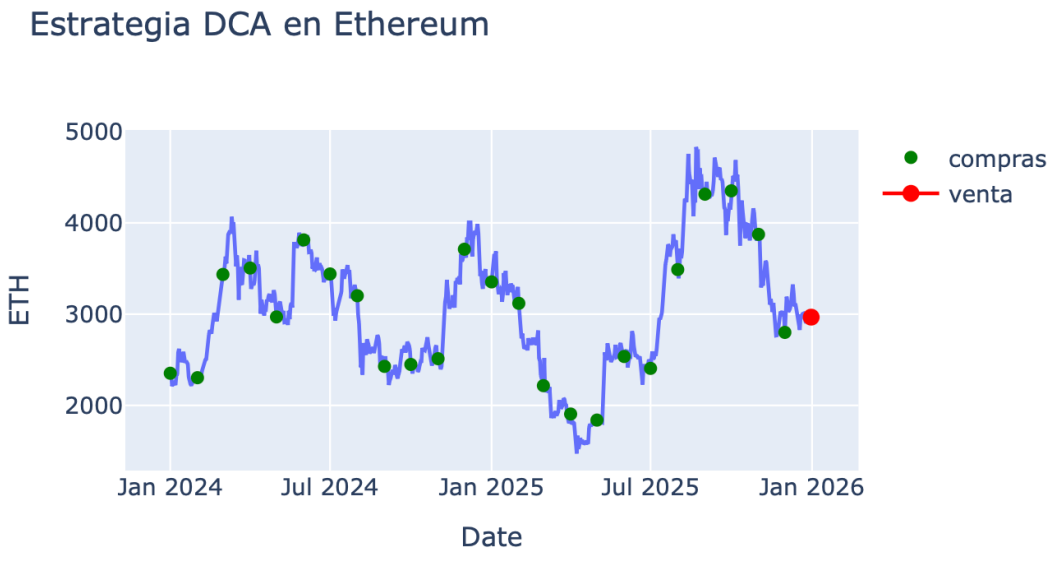


Gráfico 17 Estrategia DCA en ETH en el periodo de test

4.2.4 FEAR & GREED & HOLD CON INDICADOR REAL

En esta estrategia se han seguido las mismas normas que en el apartado de esta misma estrategia del 2018 al 2026.

En el caso de Bitcoin, la estrategia basada en el indicador Fear & Greed real obtuvo una rentabilidad del 9,81%. En esta gráfica se puede observar como el indicador es capaz de captar puntos de compra más optimos que el DCA (valles). Que la estrategia sea superada por el DCA se debe, en parte, a que la mayoría de ordenes lanzadas son casi al final del periodo de 2025 donde se realiza la venta obligatoria.



Gráfico 18 Estrategia Fear & Greed en BTC en el periodo de test

Para Ethereum, la rentabilidad se situó en un 9,07%. A diferencia de otros escenarios donde ETH quedaba muy rezagado como en el DCA, aquí obtiene un rendimiento porcentual casi idéntico al de Bitcoin. Esto sugiere que, para activos más volátiles como Ethereum, esperar a una señal de sentimiento negativo, por escasa que sea, resulta más eficiente que comprar a ciegas cada mes.



Gráfico 19 Estrategia Fear & Greed en ETH en el periodo de test

4.2.5 FEAR & GREED & HOLD CON INDICADOR PROPIO

Se mantiene la operativa de acumulación por niveles de pánico (umbral < 25), pero sustituyendo el indicador tradicional por nuestro modelo obtenido a través de Machine Learning. El objetivo es validar si la modelización del índice, basada en variables públicas y procesadas mediante técnicas de Machine Learning, ofrece una lectura más precisa o rentable de las oportunidades de compra que el propio índice original (dado que la metodología y el peso de las variables del indicador Fear & Greed original no son públicos ni auditables) o si al menos, se pueden conseguir rentabilidades similares. Al igual que en el escenario anterior, se han identificado todas las jornadas del periodo de test donde el modelo predijo niveles de miedo (inferiores a 25). El capital total se ha distribuido de forma proporcional entre estas señales para ejecutar compras recurrentes sin cierres de posición.

En el caso de Bitcoin, la estrategia basada nuestro modelo propio alcanzó una rentabilidad del 17,88%. Este resultado supera al indicador real (9,8%) y supera por muy poco por el DCA (16,01%). Esto demuestra que nuestro modelo fue capaz de identificar puntos de entrada con mayor precisión que el original, aprovechando correcciones que el indicador original ignoró o no calificó como "miedo" con la suficiente antelación.



Gráfico 20 Estrategia Fear & Greed propio en BTC en el periodo de test

Para Ethereum, la rentabilidad se disparó hasta el 29,22%. Nuestro modelo no solo pulverizó el rendimiento del indicador real (9,07%), sino que multiplicó casi por siete la rentabilidad del DCA (4,3%). Este dato es crucial: confirma que el modelo es especialmente hábil para detectar suelos en activos de mayor volatilidad como ETH y en entornos no tan favorables.



Gráfico 21 Estrategia Fear & Greed propio en ETH en el periodo de test

4.2.6 SWING TRADING CON NUESTRO MODELO FEAR & GREED

En este punto, para evaluar el potencial del modelo predictivo tanto en su capacidad de compra como en venta, se ha diseñado una estrategia de swing trading basada en umbrales extremos de

sentimiento. En este escenario, el sistema ejecuta una compra de 500 euros fijos cuando el modelo predice un valor inferior a 25 (miedo) y liquida la mitad la posición que se haya acumulado cuando el índice supera los 75 (euforia). Para que la estrategia no se quede sin posición se ha añadido la regla de que solo se ejecutará la venta si en los 15 días anteriores el mercado no ha estado por encima de 75, de forma que no haya compras en días seguidos.

Es importante puntualizar que, desde una perspectiva de gestión de carteras profesional, invertir el 5% del presupuesto se considera arriesgado, en lugar del 5%, el riesgo suele limitarse a un 1-3% por operación. Sin embargo, se ha optado por esta configuración de para garantizar una comparativa "equitativa" con el resto de las estrategias analizadas (DCA, compras únicas y Fear & Greed & Hold), permitiendo medir la eficacia del modelo en igualdad de condiciones de capital.

En esta estrategia, BTC alcanza una rentabilidad del 57,53%. Se puede observar cómo nuestro modelo de Machine Learning es capaz de captar los puntos más bajos para la compra y los más altos para la venta sobre todo en el 2024.

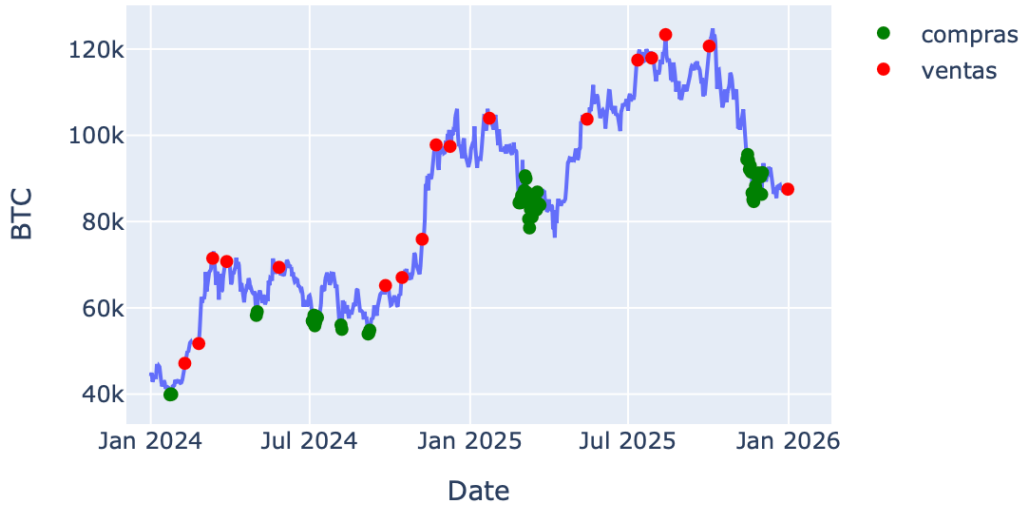


Gráfico 22 Estrategia de Swing Trading en BTC en el periodo de test

Por otra parte, si miramos ETH, nuestro modelo ha logrado sacar un 56,51% de rentabilidad. Aunque no supera a la rentabilidad de Bitcoin en esta estrategia, pulveriza a todas las demás estrategias que hemos estudiado anteriormente.

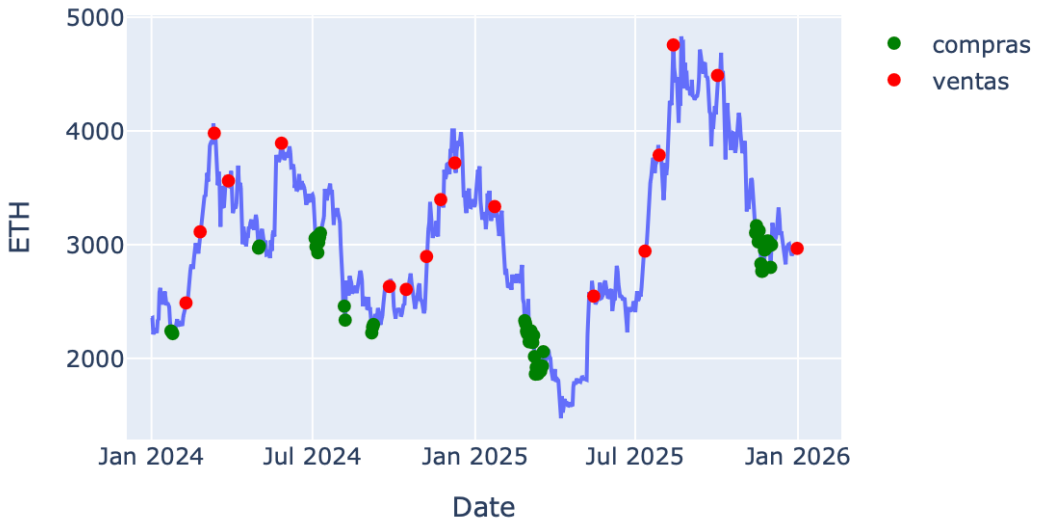


Gráfico 23 Estrategia de Swing Trading en ETH en el periodo de test

4.2.7 CONCLUSIONES

Tras contrastar los resultados de todas las metodologías aplicadas, se extraen las siguientes conclusiones fundamentales sobre la eficiencia del mercado y el valor de la inteligencia artificial:

En primer lugar, la diferencia entre la compra única de febrero (+103,15%) y la de diciembre (-5,54%) en BTC demuestra que el éxito de la inversión de compra única depende única y exclusivamente de la suerte en la fecha de entrada (para un inversor principiante). Las estrategias basadas en DCA y Fear & Greed eliminan este factor de azar.

Si comparamos las estrategias no basadas en compras únicas, nuestro modelo de Machine Learning desarrollado supera consistentemente al DCA y al Fear & Greed Real. Mientras que el DCA en Bitcoin logró un 16,01% y el Fear & Greed real consiguió un 9,8%, nuestro modelo se situó en 17,88%. Pero la diferencia notoria se encuentra en Ethereum (29,23% nuestro modelo vs 4,31% DCA y 9,06% el F&G real), validando que el algoritmo detecta zonas de compra mucho más precisas.

Por último, la estrategia ganadora (tras la compra en Febrero) sería en la que permitimos a nuestro modelo comprar en periodos de miedo y vender en periodos de euforia. En Bitcoin, logró un 57,53% y en ETH un 56,51% acumulando una rentabilidad media en el periodo de test entre BTC y ETH de 57,02%. Esto demuestra que la capacidad del modelo para "salir" del mercado en momentos de euforia es tan valiosa como su capacidad para comprar en el pánico.

5. DESARROLLO DEL ÍNDICE FEAR & GREED EN EL S&P500: ANÁLISIS DEL DESEMPEÑO Y BACKTESTING COMPARATIVO FRENTE AL MERCADO

5.1 SELECCIÓN DE VARIABLES PARA LA CONSTRUCCIÓN DEL INDICADOR

Para garantizar la validez del experimento, se ha procedido a la construcción de un dataframe que replica la forma y estructura técnica utilizada anteriormente en el mercado de criptomonedas, pero adaptada al contexto del S&P 500. En este sentido, todos los indicadores técnicos y métricas de volatilidad se han calculado sobre el precio del índice bursátil. No obstante, se han mantenido como variables de referencia el comportamiento de BTC, ETH y GOLD, dada la correlación inter-mercado detectada en el análisis exploratorio.

Una decisión clave en la ingeniería de variables ha sido la gestión de las métricas de atención (Google Trends). Debido a que el S&P 500 presenta una volatilidad estructural menor que los criptoactivos, se ha decidido conservar la variable de búsqueda "buy bitcoin"; su alta correlación con el sentimiento de riesgo global permitirá dotar al modelo de una mayor sensibilidad o "agresividad". Por otro lado, se ha sustituido la variable genérica de búsquedas cripto por "sp500_busqueda", añadiendo así un factor de información específico y personalizado para este mercado.

Finalmente, es importante subrayar que el orden de las variables en el dataframe se ha mantenido estrictamente idéntico al del modelo original de criptomonedas. Esta disposición es un requisito técnico indispensable para la correcta aplicación del Transfer Learning, ya que permite reutilizar el mismo StandardScaler (escalador de datos) y asegurar que el modelo pre-entrenado interprete correctamente cada vector de entrada al realizar las predicciones.

5.2 ANALÍSIS EXPLORATORIO

Una vez finalizado el proceso de concatenación o unión de las distintas variables en un mismo dataframe en el mismo orden que el dataframe de criptomonedas, se procedió a realizar un Análisis Exploratorio de Datos (EDA). El objetivo principal de esta fase es doble: por un lado, auditar la integridad estructural de los datos para garantizar la viabilidad del Transfer Learning y, por otro, identificar los patrones macroeconómicos y anomalías estadísticas latentes en la serie temporal.

5.2.1 ANÁLISIS ESTRUCTURAL

Lo primero que se ha realizado ha sido una comprobación y validación de las dimensiones. Se comprobó exhaustivamente que tanto el DataFrame del mercado cripto como el del S&P 500 compartieran exactamente la misma forma (shape) en su matriz, garantizando la identidad en el número de filas (coherencia en el índice temporal) y en el número y orden secuencial de las columnas (variables). Aparte, se identificó una variable almacenada en formatos no numéricos ("object") debido a los procesos de extracción. Se realizó un proceso de conversión forzada a tipo flotante (float64) en todas las columnas del dataset.

5.2.2 ANÁLISIS UNIVARIANTE

En el análisis univariante se reveló la existencia de dos periodos que alteraron drásticamente la distribución y varianza de algunas de las variables analizadas (como el VIX, el GVZ y los rangos de volatilidad diaria, entre otras): marzo de 2020 (Estallido de la pandemia de COVID-19) y abril de 2025 (inicio de las tensiones comerciales globales por parte de EEUU).

Por otra parte, este análisis univariante confirmó la presencia de valores ausentes (nulos) se correspondían exclusivamente a dos causas técnicas ya tipificadas:

- **No cotización los fines de semana:** causada por el cese de actividad en los mercados tradicionales (S&P 500, Oro/GVZ), en contraste con la naturaleza ininterrumpida (24/7) del mercado cripto.
- **Lag de Indicadores Técnicos:** Derivado del uso de ventanas móviles de cálculo (como las funciones .rolling() aplicadas al RSI de 14 sesiones, o los drawdowns de 30 y 60 días), las cuales generan inevitablemente nulos estructurales al inicio de la muestra por falta de histórico previo.

Para blindar la exactitud y la potencia predictiva del modelo, el tratamiento de estos valores nulos se ha ejecutado de manera idéntica y simétrica a la utilizada en los apartados anteriores de la investigación (mediante la combinación rigurosa de Forward Fill y Back Forward en el caso de que los nulos estén al principio de la serie).

5.2.3 ANÁLISIS BIVARIANTE

Dado que el enfoque de este proyecto se basa en la construcción de un índice a través de distintos procedimientos como el Transfer Learning o el Análisis de componentes principales (PCA), este apartado prescinde de la clásica comparativa frente a una variable target local (no disponemos aun de la variable target). En su lugar, el análisis bivariante se ha orientado hacia comparaciones entre variables que sean interesantes.

A continuación, se desglosan los hallazgos más significativos derivados del estudio cruzado de las variables predictoras:

- **VIX vs sp500_busqueda:** Al analizar la relación entre el índice de volatilidad implícita (VIX) y el volumen de búsquedas en Google de "s&p500", se identifica una coherencia estructural y una correlación positiva extremadamente alta. Ambas series temporales presentan picos de intensidad síncronos en los mismos horizontes temporales. Desde la perspectiva de las finanzas conductuales, este fenómeno es altamente lógico: un repunte drástico en el VIX denota pánico en Wall Street, lo cual genera una cobertura mediática masiva en los medios de comunicación tradicionales. Este flujo de información actúa como detonante para que el inversor minorista busque activamente información en internet sobre el estado del mercado.
- **Btc_busqueda vs sp500_busqueda:** La comparativa entre el interés digital por Bitcoin frente al S&P 500 revela una dinámica de comportamiento muy valiosa para los modelos predictivos: la variable btc_busqueda actúa estadísticamente como un indicador rezagado (lagged variable) respecto a sp500_busqueda. Visualmente se observa que los repuntes de atención en la renta variable tradicional anteceden por varios meses a los picos de interés en el ecosistema cripto. Este hallazgo sugiere un patrón de rotación de capital, ante un ciclo expansivo o una estabilización post-crisis en el S&P 500, los inversores asimilan primero dicho mercado para, posteriormente, trasladar su atención y liquidez hacia activos de mayor riesgo, como Bitcoin, en busca de rentabilidades mayores.
- **SP500_vol_7 vs VIX vs sp500_busqueda:** Al integrar la volatilidad realizada a corto plazo (SP500_vol_7) en la ecuación junto al VIX y las búsquedas digitales, se constata una confluencia matemática. Las tres variables se comportan de forma homóloga ante shocks de mercado. Mientras que el VIX mide la volatilidad esperada (opciones) y SP500_vol_7 mide la volatilidad histórica real (precios), el volumen de búsquedas mide la reacción psicológica.
- **VIX vs f&g_crypto:** Al realizar la representación del VIX con el índice nativo de sentimiento cripto (f&g_crypto) se evidencia una clara relación inversa donde los periodos de contracción de liquidez y alta volatilidad en el mercado tradicional (VIX elevado) coinciden con fases de capitulación extrema en el mercado cripto (valores mínimos de

Fear & Greed). Esto se puede evidenciar en los hitos de 2020 y 2025 donde el shock disparó el VIX, provocando un colapso automático en el sentimiento cripto hacia la zona de pánico. Por otra parte, durante el mercado bajista generalizado, el Fear & Greed cripto permaneció deprimido de forma prolongada, respaldado por un VIX consistentemente más elevado que los niveles de complacencia registrados en los periodos de expansión de 2021, 2023 y 2024.

5.2.4 ANÁLISIS MULTIVARIANTE

Al igual que en la fase bivariante, la ausencia de una variable target predictiva en este punto redirige el enfoque del análisis multivariante hacia dos objetivos fundamentales: evaluar el grado de asociación lineal de las nuevas características respecto al índice de referencia (S&P 500) y realizar la matriz de correlación global (Heatmap) donde se aprecien las correlaciones de todas las variables.

En primer lugar, para comprender cómo interactúan las variables predictoras con la tendencia general del mercado tradicional, se aislaron los coeficientes de correlación de Pearson respecto a la serie de precios del S&P 500. Los hallazgos más relevantes se describen a continuación:

- **Similitud entre los distintos mercados:** Como era de esperar tras los análisis del mercado cripto, las variables con mayor correlación lineal directa con el S&P 500 son BTC, GOLD y ETH. Esto evidencia la existencia de un macrociclo de liquidez global: en entornos expansivos, tanto la renta variable tradicional como los activos de refugio y de riesgo tecnológico tienden a apreciarse de forma paralela.
- **Importancia de las variables digitales:** El hallazgo más disruptivo del análisis es que la variable de atención social btc_busqueda exhibe una correlación con el S&P 500 superior a la de la mayoría de los indicadores de análisis técnico convencional (como el drawdown a 60 días, el sentimiento alcista o el RSI). Esto sugiere que los flujos de atención masiva en internet capturan tendencias estructurales de fondo de manera más eficiente que las fórmulas matemáticas del precio.
- **El termómetro inverso (VIX):** Se evidencia de una correlación marcadamente negativa entre el VIX y el S&P 500 aunque tampoco es una correlación negativa muy fuerte. Este comportamiento es matemáticamente consistente con la paridad descubierta en el bloque bivariante: un repunte en el índice de volatilidad actúa como el catalizador que deprime el sentimiento global (trasladándose en un colapso del Fear & Greed).
- **Atenuación de los osciladores técnicos:** Un hecho a subrayar es que los indicadores puramente técnicos muestran una correlación directa con el precio mucho más débil de lo

esperado. Las únicas métricas que mantienen cierta relevancia son las de destrucción de valor: el drawdown_60d (0.26) y el drawdown_30d (0.21). Por el contrario, variables de momento como el RSI o la volatilidad diaria apenas muestran linealidad con el precio absoluto.

5.3 CONSTRUCCIÓN DEL INDICADOR FEAR & GREED EN EL S&P 500

5.3.1 BUSQUEDA HEURÍSTICA DE PARÁMETROS

Para dar inicio a la construcción del indicador en el mercado de renta variable, se ha desarrollado un enfoque heurístico estructurado mediante una regresión lineal simplificada por bloques.

Antes de configurar la regresión, se aplicó una normalización basada en el método MinMaxScaler. Este paso técnico es indispensable debido a la gran disparidad en las escalas de los datos, ya que permite transformar todas las series a un rango homogéneo y evita que variables con valores nominales elevados (como el precio de Bitcoin) distorsionen el peso del resto de componentes.

A partir de ahí, las variables seleccionadas se clasificaron en tres submodelos específicos:

- **Variables de Mercado:** Formado por los activos de referencia globales (BTC, S&P 500 y GOLD).
- **Variables Técnicas:** Incluye métricas de seguimiento de tendencias y volatilidad como los drawdowns de 30 y 60 periodos, la distancia a las bandas de Bollinger y la distancia a las medias móviles. Se seleccionaron estos indicadores específicos debido a que presentan una correlación más estrecha con el fear & greed cripto.
- **Variables de Sentimiento:** Reúne el índice Fear & Greed de criptomonedas, el sentimiento alcista y el índice VIX. En el caso particular del VIX, al funcionar de forma natural como el "índice del miedo" (correlación inversa con el mercado), se le aplicó una transformación matemática inversa para alinear su comportamiento con la dirección de las demás variables de optimismo.

Para establecer las ponderaciones definitivas de la ecuación, se llevó a cabo un proceso iterativo de optimización manual, contrastando el comportamiento del índice sintético frente al histórico real del S&P 500. Con la finalidad de verificar la hipótesis central de este TFM —evaluar el impacto real de la psicología de masas frente a las señales técnicas tradicionales—, la asignación final de

pesos se fijó en un 0,6 para el bloque de sentimiento, un 0,2 para las variables técnicas y un 0,2 para las variables de mercado.

5.3.2 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

Tras el enfoque heurístico, se exploró una metodología basada en el Análisis de Componentes Principales (PCA). El objetivo era eliminar el sesgo humano en la asignación de pesos y permitir que el algoritmo identificara la estructura latente del sentimiento del mercado a través de la varianza de los datos.

Para este proceso, se procedió a la estandarización previa de todas las variables para asegurar que las diferencias en las escalas de medida no distorsionaran el modelo. Se configuró el algoritmo para extraer un único componente principal (PC1), bajo la hipótesis de que este capturaría la mayor parte de la información relativa al estado emocional y tendencial del S&P 500.

Sin embargo, tras analizar los resultados, se determinó que este método no es apto para los objetivos de este estudio por las siguientes razones:

- **Discrepancia con el índice original:** El índice generado mediante el PC1 no presentó una correlación lógica ni visual con el comportamiento esperado de un indicador Fear & Greed. A diferencia de la versión heurística, el PCA mostró una señal errática que no lograba identificar con claridad los periodos de euforia o pánico.
- **Ineficacia del Reescalado:** Se intentó corregir la interpretación visual aplicando un escalado MinMaxScaler [0, 100] para normalizar el rango. No obstante, incluso tras este ajuste, los valores resultantes carecían de la sensibilidad necesaria para actuar como una herramienta de toma de decisiones financiera.

5.3.3 TRANSFER LEARNING

El último bloque de la metodología se basa en el Transfer Learning (Aprendizaje por Transferencia). Esta técnica asume que los patrones de comportamiento humano y la psicología de masas detectado en el mercado cripto pueden ser extrapolable al mercado de renta variable tradicional, por ello se “transferirá” el modelo utilizado en criptomonedas para este mercado.

Para garantizar la integridad del modelo pre-entrenado, se siguieron los siguientes pasos técnicos:

- **Homogeneización de Variables:** Se realizó un proceso de renaming de las columnas del dataset del S&P 500 para que coincidieran exactamente con las etiquetas utilizadas en el entrenamiento original del modelo cripto. Esto es crítico, ya que la arquitectura del escalado y del modelo esperan una estructura de entrada (input) idéntica.
- **Consistencia del Escalado:** Se utilizó el escalador original (fitted scaler) del modelo de criptomonedas.
- **Generación del Índice Sintético:** Tras eliminar la variable target, se ejecutó la función .predict() para obtener nuestro índice sintético del S&P 500.

Al observar los resultados preliminares, se detectó que el índice generado para el S&P 500 presentaba una volatilidad significativamente menor que su homólogo cripto. Esto es lógico, dado que los activos tradicionales se mueven en rangos de varianza mucho más estrechos. Con nuestro modelo sintético se realizarían 63 compras en una estrategia que se basase en comprar por debajo de valores de 25. Para que el índice se vuelva algo más agresivo y pueda operar más veces en el back testing estratégico se ha realizado un MinMaxScaler sobre el índice. Después del escalado el modelo opera 42 con lo que se consigue el resultado opuesto, menos entradas de compra. En la comparación de estrategias veremos cuál de las dos opciones obtiene mejores resultados.

5.4 BACK TESTING DE LAS ESTRATEGIAS EN EL PERIODO 2018-2025

Como en el backtesting en el mercado de criptomonedas, el objetivo de este punto es contrastar la eficacia de los índices sintéticos creados frente a las estrategias convencionales. Las estrategias analizadas son: DCA, Fear & Greed (Original), búsqueda heurística, transfer learning (sin escalar), transfer learning (escalado). Como en los puntos anteriores, se han establecido reglas para que sea justa la comparación:

- **Capital Inicial:** 10.000 € de presupuesto base.
- **Costes Operativos:** No se computa ningún tipo de comisión de corretaje o cánones de bolsa, facilitando una comparación pura del rendimiento de los algoritmos.
- **Horizonte Temporal:** Del 2 de febrero de 2018 al 31 de Diciembre de 2025.

5.3.2 DOLLAR COST AVERAGE (DCA)

Para validar el desempeño del modelo propuesto, se estableció como referencia la estrategia Dollar Cost Averaging (DCA) que es una de las estrategias preferidas por los inversores debido a

su sencillez. Esta estrategia arrojó una rentabilidad acumulada del 78,60% en el periodo 2018-2026.

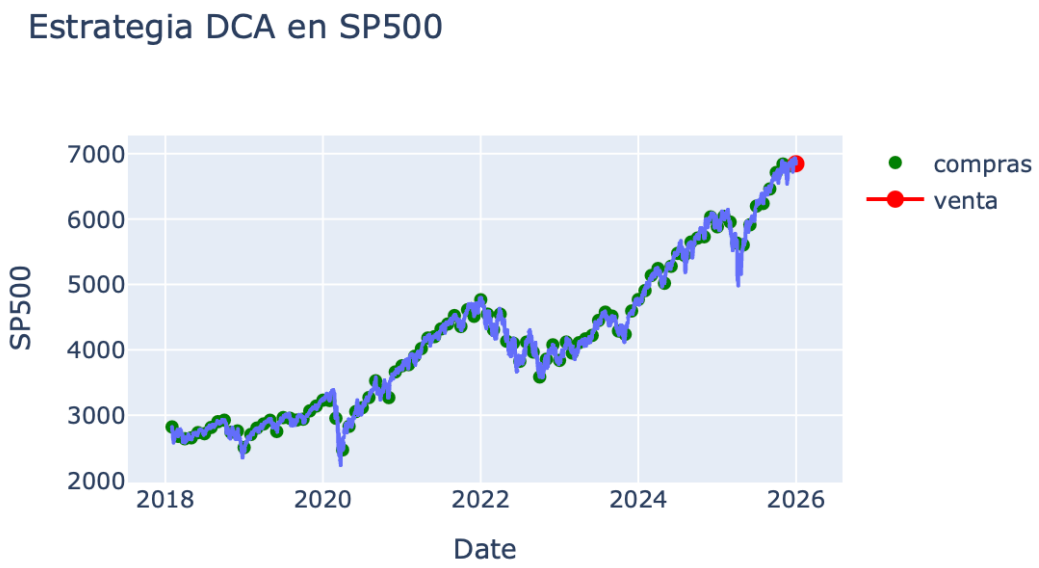


Gráfico 24 Estrategia DCA en S&P 500 en el periodo 2018-2025

5.3.3 FEAR & GREED CRIPTO (ORIGINAL)

Un hito relevante de este estudio es el desempeño del índice Fear & Greed original del mercado cripto aplicado al S&P 500. A pesar de no ser un indicador diseñado para la renta variable tradicional, se comentó que el índice tiene una correlación intermercado sorprendentemente alta, llegando a superar en precisión a la correlación mantenida con activos como Ethereum (ETH) y esto lo plasma en los resultados obtenidos.

El modelo alcanzó un 95,18%, superando significativamente el 78,60% al del DCA. El hecho de que un indicador externo bata a una estrategia pasiva del propio mercado refuerza la teoría de que el sentimiento psicológico es un factor determinante.

Como se observa en la representación gráfica, el modelo demuestra una capacidad notable para identificar suelos de mercado, ejecutando órdenes de compra en niveles de pánico que históricamente preceden a recuperaciones importantes.

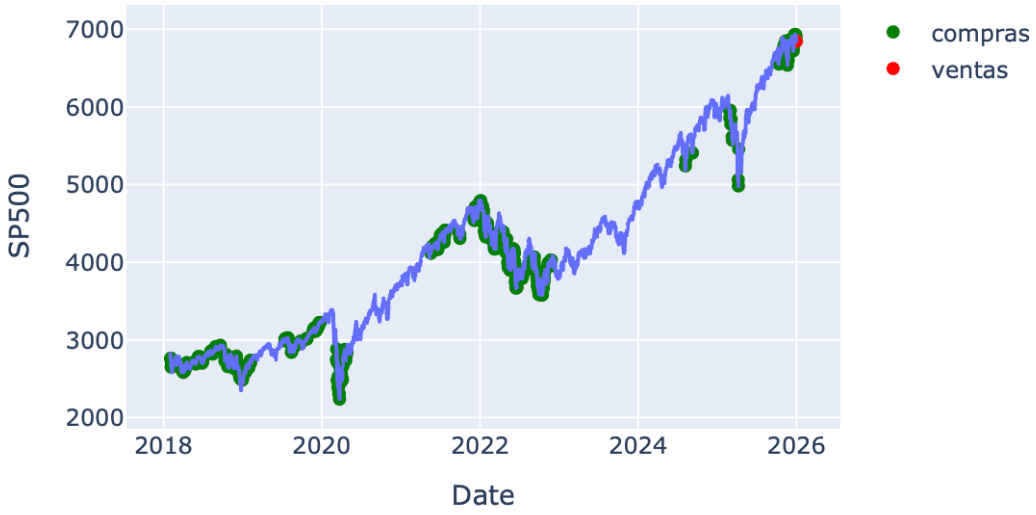


Gráfico 25 Estrategia Fear & Greed cripto en S&P 500 en el periodo 2018-2025

5.3.4 BÚSQUEDA HEURÍSTICA DE PARÁMETROS

Tras el proceso de refinamiento del modelo de regresión lineal mediante el enfoque heurístico, se procedió a evaluar su desempeño en el entorno de backtesting. Los resultados confirman la eficacia de la optimización manual de pesos y parámetros sobre las variables de sentimiento.

Esta estrategia alcanzó un 112,4%. El modelo no solo bate al DCA (78,60%), sino que genera un rendimiento excedente cercano al 50% adicional en el horizonte temporal de ocho años. Esto demuestra que las variables de sentimiento y las técnicas pueden marcar la diferencia.

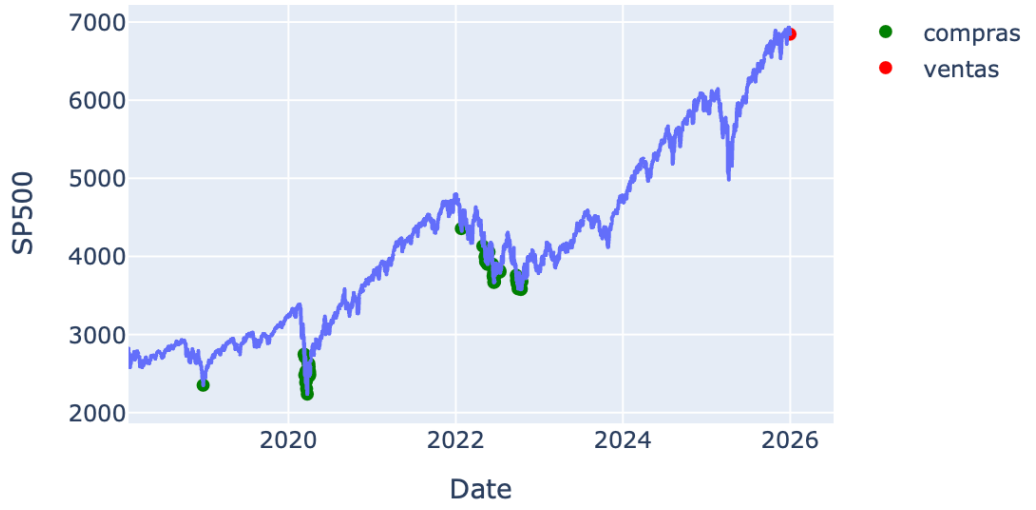


Gráfico 26 Estrategia Fear & Greed busqueda heurística en S&P 500 en el periodo 2018-2025

5.3.5 TRANSFER LEARNING SIN ESCALAR

El análisis del modelo de Transfer Learning marca el punto de inflexión cuantitativo de este estudio. Esta estrategia arrojó una rentabilidad del 133,62%. Este modelo supera casi en un 40% de rentabilidad al índice Fear & Greed Cripto original. Este incremento demuestra empíricamente que la sustitución de las variables originales del S&P 500 aporta un contexto crítico que el modelo aprovecha para refinar sus decisiones. Por otra parte, la rentabilidad obtenida supera en más de un 50% al rendimiento del DCA (78,60%). Lo más destacable es que el modelo logra esta diferencia manteniendo una simplicidad operativa idéntica a la de la gestión pasiva, ejecutando órdenes de compra cuando el indicador está por debajo de 25 sin añadir complejidad.

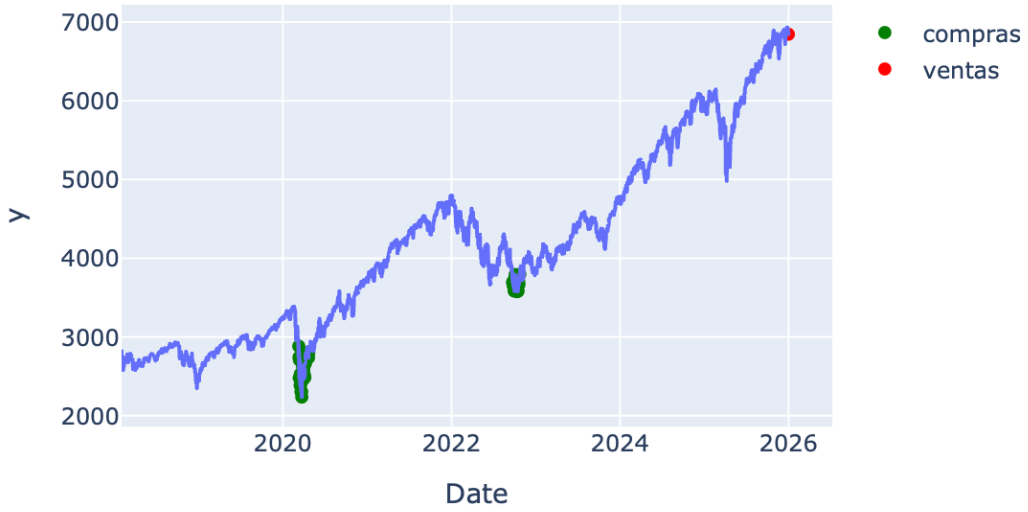


Gráfico 27 Estrategia Fear & Greed transfer learning no escalado en S&P 500 en el periodo 2018-2025

5.3.6 TRANSFER LEARNING ESCALADO

La última variante analizada corresponde al índice de Transfer Learning sometido a un escalado MinMaxScaler. Como se detalló en la metodología, el objetivo de esta normalización era volver más agresivo el índice para adaptarlo a la menor volatilidad del S&P 500. Esta estrategia arrojó una rentabilidad acumulada del 152,55%. El modelo escalado bate con solvencia tanto al Benchmark pasivo (DCA, 78,60%) como al índice Fear & Greed Cripto original (95,18%) y a la búsqueda heurística (112,61%). Por otro lado demuestra que a veces en el mundo de las inversiones es mejor realizar menos operaciones si estas son más precisas superando también al modelo construido a través de transfer learning sin escalar (133,62%).

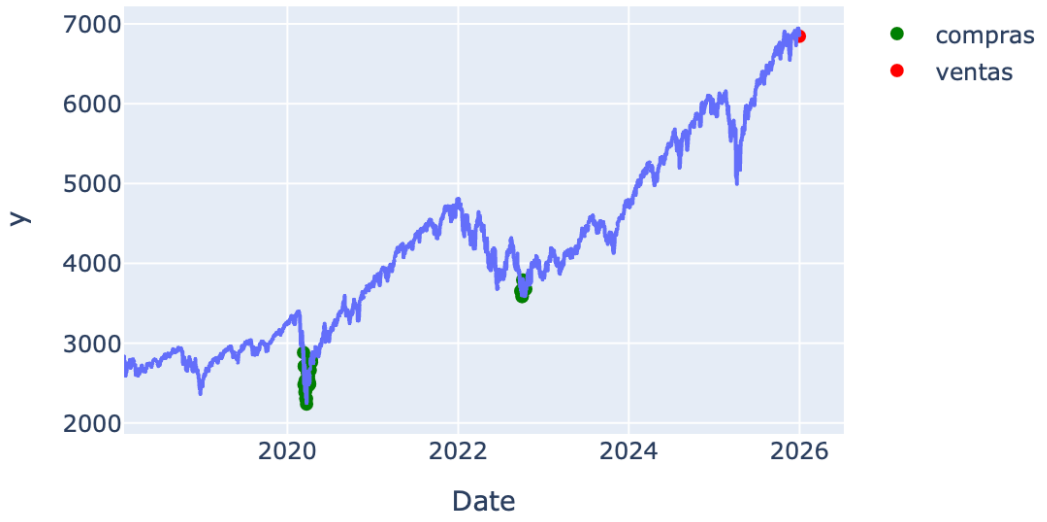


Gráfico 28 Estrategia Fear & Greed transfer learning escalado en S&P 500 en el periodo de 2018-2025

6. DESARROLLO DEL ÍNDICE FEAR & GREED EN EL ORO: ANÁLISIS DEL DESEMPEÑO Y BACKTESTING COMPARATIVO FRENTE AL MERCADO

6.1 SELECCIÓN DE VARIABLES PARA LA CONSTRUCCIÓN DEL INDICADOR

Tras haber consolidado el entorno de renta variable y de las criptomonedas, se procede a estructurar el tercer y último conjunto de datos de la investigación: el mercado del oro (GOLD). Para garantizar la viabilidad metodológica del Transfer Learning, este proceso se ha diseñado bajo un principio de simetría matricial, replicando la arquitectura de características (feature engineering) y el orden secuencial del mercado de renta variable (S&P 500).

Con el fin de capturar la naturaleza específica del oro como activo de refugio tradicional, manteniendo al mismo tiempo la coherencia conceptual, se han implementado dos sustituciones de variables fundamentales:

- **Sustitución de la volatilidad implícita (VIX por GVZ):** El índice VIX, al ser un proxy exclusivo del miedo en la renta variable (S&P 500), ha sido sustituido por el Gold Volatility Index (GVZ). El GVZ funciona de manera homónima al VIX, midiendo la volatilidad implícita a 30 días del mercado del oro. Esto asegura que el algoritmo reciba una señal de estrés financiero nativa y directamente vinculada a la incertidumbre del oro.
- **Adaptación de las búsquedas (sp500_busqueda por gold_busqueda):** Aunque se mantiene la búsqueda de “bitcoin”, la otra busqueda de atención masiva extraída de

Google Trends se ha reconfigurado utilizando el término de búsqueda "gold". De este modo, el modelo mantiene su capacidad para evaluar el impacto de las finanzas conductuales y la atención del inversor minorista, pero adaptada al flujo de interés específico del oro.

El resto de las variables técnicas (como el RSI, las bandas de Bollinger, las tasas de cambio o *Rate of Change*, y las distancias a las medias móviles entre otras) se han calculado utilizando exactamente las mismas ecuaciones y ventanas temporales paramétricas sobre la serie de precios del oro, asegurando la homogeneidad analítica.

6.2 ANÁLISIS EXPLORATORIO

6.2.1 ANÁLISIS UNIVARIANTE

Dada la naturaleza del dataset del oro y su simetría con el entorno del S&P 500 analizado previamente, la fase de Análisis Exploratorio de Datos (EDA) se enfocó en detectar las inconsistencias estructurales esperadas en la serie temporal. Al tratarse de un mercado tradicional con un calendario laboral idéntico al bursátil, el análisis exploratorio confirmó la presencia de valores nulos derivados exactamente de las mismas dos causas técnicas predecibles que nos encontrábamos en el mercado de renta variable:

- **Nulos por la no cotización en fin de semana:** El mercado del oro cesa su cotización durante los fines de semana y festivos. Al integrarse en un índice de 7 días, estas ventanas temporales generan nulos estructurales de forma recurrente en algunas variables.
- **Nulos por ventana móvil:** Variables técnicas esenciales como el RSI, las Bandas de Bollinger, las tasas de variación (pct_change()) y los indicadores de momento basados en funciones .rolling() (como los drawdowns a 30 y 60 días) requieren un histórico mínimo de datos pasados para calcular su primer valor. Esto genera un vacío de información concentrado exclusivamente al inicio de la serie temporal.

Para no distorsionar la distribución matemática de la matriz ni alterar las reglas que hemos aplicado anteriormente, se aplicó una réplica exacta de la política de limpieza implementada en el S&P 500.

6.2.2 ANÁLISIS BIVARIANTE

Al mantener la consistencia metodológica aplicada en el bloque previo, y ante la ausencia de una variable target, el análisis bivariante del mercado del oro (GOLD) se enfoca en descifrar las interacciones entre distintas variables.

A continuación, se exponen los pares de variables analizados y las conclusiones analíticas extraídas de sus representaciones visuales:

- **GOLD vs dominancia_bitcoin:** La comparativa entre el precio del oro y la dominancia de mercado de Bitcoin revela un comportamiento sumamente interesante. Se detecta un horizonte temporal específico donde el oro se estanca en un canal lateralizado coincidiendo con un desplome vertical en la dominancia de Bitcoin. La hipótesis financiera que explica esta divergencia se fundamenta en un proceso de rotación de carteras hacia activos de riesgo más elevado. Durante este periodo, el mercado cripto experimenta una fase marcadamente alcista (bull market). Los flujos de capital no solo drenan la liquidez del oro (frenando su ascenso), sino que esquivan al Bitcoin para concentrarse masivamente en las Altcoins (como ETH, SOL o ADA). Al cruzar esta gráfica con la serie histórica de Ethereum, se constata empíricamente que este periodo coincide de forma exacta con la fase de una gran revalorización de ETH, validando la hipótesis de migración de valor.
- **GVZ vs GOLD:** A diferencia del mercado de renta variable (donde el VIX reacciona de forma asimétrica, disparándose casi exclusivamente ante las caídas), la relación entre el oro y su índice de volatilidad implícita (GVZ) muestra una naturaleza bidireccional frente al estrés. El gráfico bivariante revela que el GVZ registra picos de intensidad severos tanto ante colapsos del precio del metal como ante rupturas alcistas.
- **Btc_busqueda vs gold_busqueda:** Al contrastar las métricas de Google Trends, se rompe el patrón de letargo o rezago temporal (lag) que habíamos identificado entre el SP 500 y las criptomonedas. En este escenario, la búsqueda del oro (gold_busqueda) exhibe un comportamiento maduro con pequeños picos y de base estable a lo largo de la serie, experimentando un crecimiento sostenido a partir del año 2024 debido a su revalorización. Por su parte, btc_busqueda se rige por ciclos emocionales puros: muestra una hiperextensión casi vertical en 2021 impulsada por la euforia y el auge del minorista, para posteriormente colapsar de forma prolongada durante el mercado bajista.
- **GOLD_vol_7 vs GVZ vs gold_busqueda:** Al evaluar conjuntamente la volatilidad realizada a 7 días, la volatilidad implícita y la acción de búsqueda en internet para el oro, se confirma que la confluencia de este bloque es visible, pero sensiblemente más atenuada que en el ecosistema del S&P 500.

- **GVZ vs f&g_crypto:** Al igual que ocurría con el VIX, se observa que los entornos de máxima incertidumbre geopolítica y macroeconómica expanden el GVZ al tiempo que deprimen el sentimiento cripto hacia zonas de miedo.

6.2.3 ANALÍSIS MULTIVARIANTE

El análisis multivariante del dataset del oro (GOLD) se ha diseñado con el fin de auditar la matriz de correlación global (Heatmap) y evaluar el nivel de asociación lineal de las variables predictoras respecto al activo de referencia.

En primer lugar, se han realizado los coeficientes de correlación de Pearson respecto al precio del oro:

- **Relación entre GOLD-SP500-BTC:** Se confirma una vez más la estrecha e intensa correlación positiva entre el Oro, el S&P 500 y Bitcoin.
- **La eficiencia del interés digital:** Al aislar los coeficientes de Pearson con el valor del oro se puede observar que la correlación entre la variable “gold_busqueda” y el oro es muy alta. Para poner en perspectiva, la correlación entre el SP500 y “sp500_busqueda” era de 0,43 y la de “gold_busqueda” y el oro es 0,87.
- **Mayor importancia de las variables técnicas:** Otro hallazgo crítico es que los indicadores de análisis técnico aplicados al oro muestran coeficientes de correlación sensiblemente más altos que sus homólogos en el S&P 500. Las métricas de posicionamiento estructural, como dist_SMA_50, dist_bollinger_low y GOLD_vol_7, reflejan una fuerte linealidad con el precio del oro.
- **Asimetría entre el VIX y el GVZ:** Mientras que el apartado del S&P 500 podíamos ver que el VIX y el S&P 500 tenían una correlación negativa, en el apartado del oro se puede ver que GVZ y el oro tienen una correlación positiva.

La inspección detallada de la matriz de correlación global del mercado del oro permite validar de forma empírica la estructura interna del dataset, arrojando las siguientes conclusiones sobre sus interacciones multivariantes:

- **Atenuación del núcleo de incertidumbre:** El mapa de calor confirma visualmente la hipótesis planteada en el análisis bivariante: la tríada compuesta por GOLD_vol_7, el GVZ y gold_busqueda exhibe una pérdida de correlación lineal en comparación con su homóloga en el S&P 500.
- **Correlación entre variables técnicas:** Se detecta un área de alta correlación entre el RSI y el roc_15d. Dado que ambas variables analizan la velocidad de la tasa de cambio en

ventanas temporales, esta correlación positiva es matemáticamente coherente. Lo más relevante es cómo este bloque de impulso se conecta con la distancia a la media móvil estructural (dist_SMA_50) y las métricas de corrección (drawdown_30d y drawdown_60d).

- **Correlación entre variables de movimiento diario del precio:** Finalmente, el mapa de calor revela una correlación positiva sobresaliente entre el range_relative y la volatilidad_med_diaria.

6.3 CONSTRUCCIÓN DEL INDICADOR FEAR & GREED EN EL ORO

6.3.1 BÚSQUEDA HEURÍSTICA DE PARÁMETROS

Al igual que en el apartado del S&P 500 se ha optado por una aproximación heurística basada en una regresión lineal simple por bloques. Como innovación exclusiva para el mercado del oro en este método, se ha incorporado la variable DFII10 (Market Yield on U.S. Treasury Securities at 10-Year Constant Maturity, Inflation-Indexed), que representa el rendimiento de los bonos del Tesoro de EE. UU. a 10 años indexados a la inflación.

Debido a que las variables presentan escalas numéricas muy diversas (por ejemplo, Bitcoin cotiza en miles de unidades mientras que el RSI es un oscilador acotado entre 0 y 100), se procedió a normalizar todas las variables mediante el método MinMaxScaler.

Tras el proceso de normalización, el conjunto de datos se organizó en tres bloques o submodelos bien definidos:

- **Variables de Mercado:** Incluye BTC, SP500 y GOLD, manteniendo la misma estructura utilizada en el apartado del S&P 500, con el fin de capturar la tendencia general y la liquidez global.
- **Variables Técnicas:** Agrupa los drawdowns a 30 y 60 días, la distancia a la media móvil de 50 periodos, el RSI y el ROC de 15 días, orientados a identificar zonas de sobreventa o agotamiento de la tendencia.
- **Variables de Sentimiento:** Reúne el Fear & Greed de cripto, el GVZ, la variable macro DFII10 y el sentimiento alcista del S&P 500.

Para la construcción del indicador final del oro, y con el objetivo de contrastar la hipótesis central del TFM —determinar la relevancia real del sentimiento en los mercados financieros frente al análisis puramente técnico—, se diseñó una función de agregación lineal donde los pesos se distribuyeron de la siguiente manera: 0,6 las variables de sentimiento y 0,2 tanto las variables técnicas como las de mercado.

6.3.2 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

El segundo enfoque evaluado consistió en la aplicación del Análisis de Componentes Principales (PCA) sobre el dataframe del oro, con el objetivo de extraer una primera componente que funcionara como índice sintético. El algoritmo se testeó en dos escenarios: con los datos brutos y aplicando previamente la normalización MinMaxScaler.

Sin embargo, al igual que ocurrió en el análisis del S&P 500, los resultados obtenidos no fueron los esperados. El PCA no logró aislar de forma limpia la señal de sentimiento. Al no ofrecer un indicador con una lógica financiera sólida ni una dirección consistente, se descartó este método para el desarrollo de la estrategia o backtesting.

6.3.3 TRANSFER LEARNING

El último método evaluado se fundamenta en la aplicación de Transfer Learning (aprendizaje por transferencia). Para ello, se reutiliza la arquitectura del Random Forest y el peso de los componentes optimizados previamente en el ecosistema de las criptomonedas, transfiriendo ese conocimiento directamente al mercado del oro. Para poder realizar se modificar los nombres de las variables para que coincidan con la nomenclatura de utilizada en las criptomonedas y se empleó el mismo escalador que en el apartado de criptomonedas.

Al ejecutar las primeras pruebas de predicción (predict) bajo este entorno, el índice sintético resultante mostró un comportamiento marcadamente conservador. Dado que el oro exhibe de forma nativa una volatilidad y unas variaciones de precio mucho menores que el mercado de criptomonedas, el indicador apenas registró 5 lecturas por debajo del umbral de 25 (zona de pánico o infravaloración) a lo largo de todo del periodo estudiado.

Con el objetivo de corregir este desajuste y volver el indicador más reactivo o "agresivo" ante las anomalías del mercado, se procedió a aplicar un MinMaxScaler secundario sobre la propia salida de la predicción. Tras este reescalado, el modelo expandió su sensibilidad, logrando registrar 444 entradas por debajo del nivel de 25.

En el siguiente capítulo de backtesting se compararán ambas alternativas para determinar estadísticamente si es preferible trabajar con la señal ajustada por el MinMaxScaler o si, por el contrario, ofrece mejores métricas de retorno la versión conservadora original con menos señales pero de mayor fiabilidad.

6.4 BACK TESTING DE LAS ESTRATEGIAS EN EL PERIODO 2018-2025

Las reglas ejecutadas en estas estrategias son exactamente las mismas que en el apartado del S&P 500.

6.4.1 DOLLAR COST AVERAGE (DCA)

La estrategia Dollar Cost Averaging (DCA) sobre el mercado del oro entre el año 2018 y finales de 2025, arrojó una rentabilidad acumulada del 140%, un rendimiento considerable que permitió más que duplicar el capital total invertido durante el periodo.

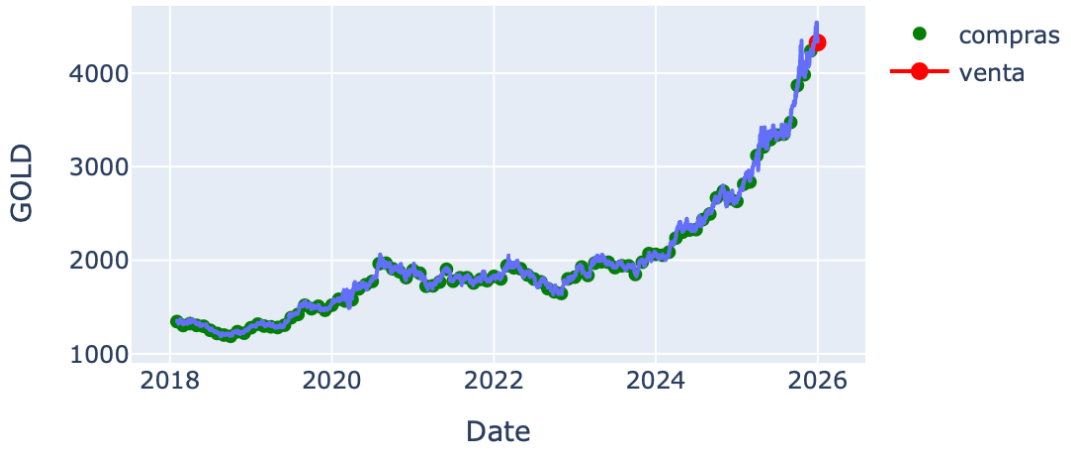


Gráfico 29 Estrategia DCA en oro en el periodo 2018-2025

6.4.2 FEAR & GREED CRIPTO (ORIGINAL)

Al realizar la estrategia con el índice fear & greed de criptomonedas se obtuvo una rentabilidad acumulada del 160,27%, lo que representa un incremento neto de aproximadamente el 20% en comparación con el rendimiento del 140% registrado por el modelo de control DCA. Este diferencial positivo resulta de gran relevancia para la investigación, ya que demuestra empíricamente el objetivo central de este análisis: el sentimiento y la conducta de un mercado alternativo pueden ser transferidos con éxito para optimizar las decisiones de inversión pese a no ser un indicador del oro.



Gráfico 30 Estrategia Fear & Greed cripto en oro en el periodo 2018-2025

6.4.3 BÚSQUEDA HEURÍSTICA DE PARÁMETROS

Al evaluar la estrategia basada en la búsqueda heurística de parámetros para el oro, se obtuvo una rentabilidad acumulada del 186,73% al cierre del periodo de análisis. Este resultado representa un hito muy significativo en el estudio, ya que logra superar por más de un 40% al modelo de control DCA y por más de un 20% a la estrategia del Fear & Greed de criptomonedas. Desde un punto de vista analítico, este notable diferencial positivo confirma que la integración de variables específicas y nativas del mercado del oro (como la variable DFII10 o la volatilidad implícita del GVZ) tiene un impacto directo y determinante en la optimización de las señales.

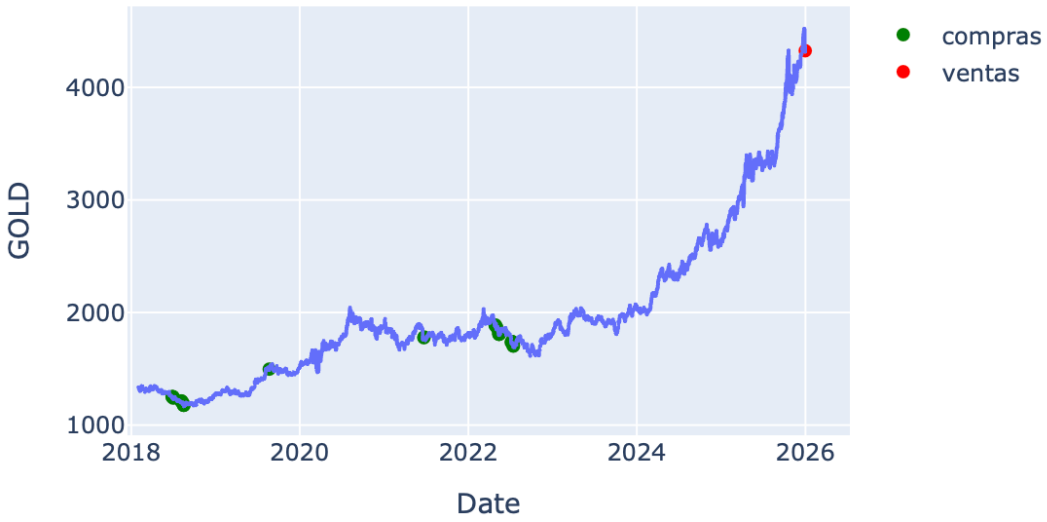


Gráfico 31 Estrategia Fear & Greed búsqueda heurística en Oro en el periodo 2018-2025

6.4.4 TRANSFER LEARNING SIN ESCALAR

Por otra parte, al evaluar el indicador obtenido mediante la estrategia de Transfer Learning en su versión original sin reescalar, se alcanzó una rentabilidad acumulada del 184,61%. Este rendimiento logra batir con solvencia tanto al modelo pasivo DCA como a la estrategia basada de forma exclusiva en el Fear & Greed de criptomonedas, confirmando la validez de transferir la arquitectura de redes neuronales entre mercados de distinta naturaleza. No obstante, este enfoque no consiguió batir el rendimiento de la búsqueda heurística de parámetros específica del oro.

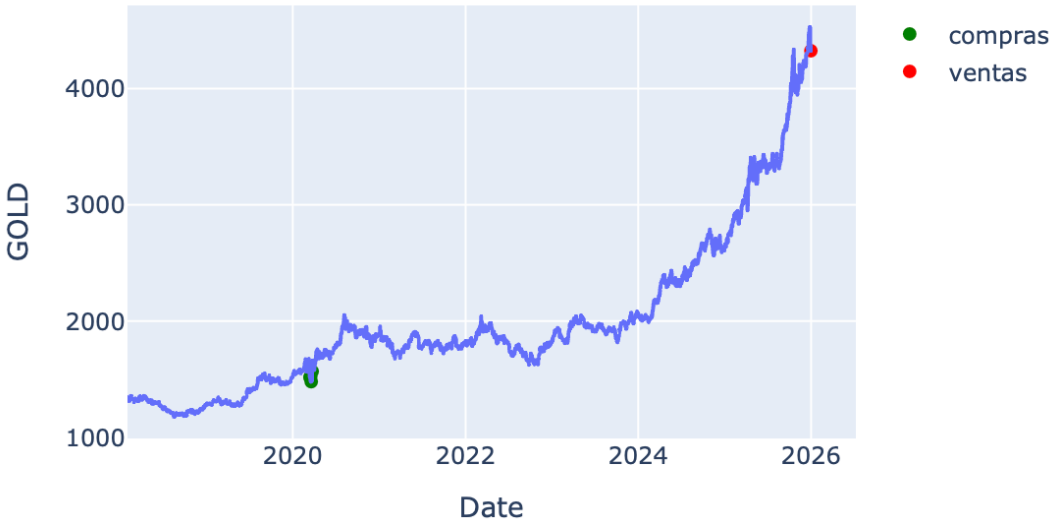


Gráfico 32 Estrategia Fear & Greed transfer learning sin escalar en Oro en el periodo 2018-2025

6.4.5 TRANSFER LEARNING ESCALADO

Por último, la versión de la estrategia de Transfer Learning modificada mediante el reescalado secundario arrojó una rentabilidad acumulada del 176,96%. Al contrastar este resultado con el rendimiento del modelo original sin escalar (184,61%), se llega a la conclusión de que, a pesar de que el proceso de escala expande la sensibilidad del indicador y genera un volumen de señales de compra considerablemente mayor estas operaciones no añaden más rentabilidad a la cartera.

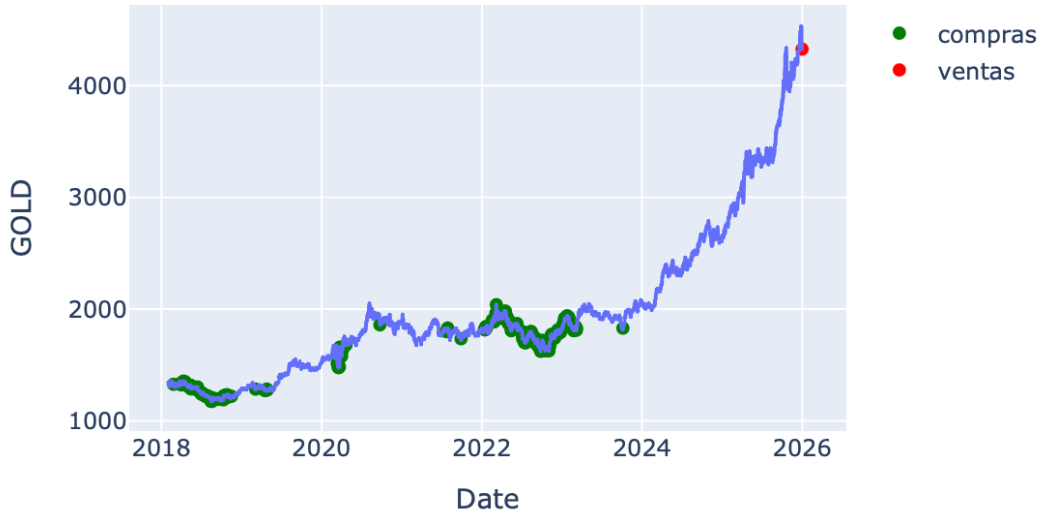


Gráfico 33 Estrategia Fear & Greed transfer learning escalado en Oro en el periodo 2018-2025

7. CONCLUSIONES

El desarrollo de este trabajo permite extraer conclusiones muy claras sobre la gestión de activos y el uso de variables alternativas en el diseño de estrategias de inversión. En primer lugar, el estudio demuestra que existe una alta correlación entre los activos estudiados (mercado de criptomonedas, S&P 500 y oro) esto puede ser bueno si tienes una cartera diversificada y sabes del conocimiento de esta correlación o malo si no tienes una cartera diversificada y tienes mucho peso en estos mercados (tu portafolio sufrirá mucho en mercados bajistas). Por otra parte, en este trabajo, se ha evidenciado que incorporar variables de sentimiento y diseñar modelos dinámicos para operar en diferentes mercados financieros genera una rentabilidad notablemente mayor que los enfoques pasivos tradicionales durante el periodo analizado.

La ventaja de utilizar estrategias activas basadas en la psicología del inversor, en comparación con métodos estáticos que operan siempre igual como el Dollar Cost Averaging (DCA), queda plenamente demostrada con los datos obtenidos en el periodo 2018-2025:

- En el mercado cripto, el DCA tradicional obtuvo una rentabilidad del 478,73% en BTC y del 473,23% en ETH, mientras que la estrategia guiada por el indicador Fear & Greed logró alcanzar un 692,8% en BTC y un 708,22% en ETH.
- En el S&P 500, el método pasivo registró un rendimiento del 78,6%, viéndose ampliamente superado por todas las estrategias en las que incluimos los sentimientos: Transfer Learning sin escalar (133,62%), Transfer Learning escalado (152,55%) y búsqueda heurística (112,4%).

- En el mercado del oro, frente al 140,08% generado por el DCA, las estrategias desarrolladas superarían estas cifras: Transfer Learning sin escalar (184,61%), Transfer Learning escalado (176,96%) y búsqueda heurística (186,73%).

Más allá del éxito de los modelos algorítmicos para exprimir el mercado a través del sentimiento, la investigación subraya una premisa fundamental: la necesidad imperativa de invertir el dinero. Debido a que los activos financieros cotizan en relación con monedas fiduciarias —las cuales pierden valor constantemente por la inflación—, dejar el dinero parado en el banco equivale a asumir una pérdida garantizada de poder adquisitivo año tras año. En conclusión, este trabajo no solo valida que las metodologías avanzadas de inversión funcionan, sino que recalca que, en el entorno actual, la inacción financiera es el mayor riesgo para nuestro patrimonio.

8. BIBLIOGRAFÍA

AAII. (s.f.). *AAII Sentiment Survey: Sentiment results*. American Association of Individual Investors. Recuperado el 22 de marzo de 2026, de https://www.aaii.com/sentimentsurvey/sent_results

CaixaBank. (s.f.). *Historia del oro*. CaixaBank Esfera. Recuperado el 25 de marzo de 2026, de https://www.caixabank.com/es/esfera/content/historia-del-oro

CNN Business. (s.f.). *Fear & Greed Index*. Cable News Network. Recuperado el 25 de marzo de 2026, de https://edition.cnn.com/markets/fear-and-greed

CoinMarketCap. (s.f.). *Crypto market cycle indicators*. https://coinmarketcap.com/charts/crypto-market-cycle-indicators/

IG. (2020, 2 de marzo). *¿Qué es la hipótesis del mercado eficiente (EMH)?* IG España. https://www.ig.com/es/estrategias-de-trading/-que-es-la-hipotesis-del-mercado-eficiente--emh---200302

Binance Academy. (s.f.). *¿Qué es el índice de miedo y codicia (Fear and Greed Index) de cripto?* Binance. https://www.binance.com/en/academy/articles/what-is-the-crypto-fear-and-greed-index

Bloomenthal, A. (2024, 18 de marzo). *Behavioral finance: Definition, examples, and key concepts*. Investopedia. https://www.investopedia.com/terms/b/behavioralfinance.asp

Glassnode. (s.f.). *Bitcoin: Fear & Greed Index metric documentation*. Glassnode Studio. https://studio.glassnode.com/metrics